

Data Mining and Its Applications

数据挖掘与应用

第1章：数据挖掘概述

目录

什么是数据挖掘

统计思想在数据挖掘中的重要性

案例：谷歌流感趋势

案例：人工智能选美比赛

案例：用人工智能识别性取向

案例：沃森肿瘤医疗系统

数据挖掘的应用案例

案例：企业贷款信用风险

案例：中国海关

案例：意大利信息系统联盟


案例：零售业

案例：麻省理工的十亿级价格项目

CRISP-DM数据挖掘方法论

SEMMA数据挖掘方法论

持续改进的过程



- ▶ 根据组织所积累的经验收集可度量的数据（包括内部数据和外部数据）。
- ▶ 对这些数据进行分析后，提炼出对运营管理有指导意义的新知识。
- ▶ 进一步改进决策、改善运营活动。

什么是数据挖掘

数据挖掘是对大量数据进行探索和分析、以便发现有意义的模式和规则的过程。(Berry and Linoff, 2000)

数据挖掘活动

- ▶ 无监督数据挖掘：对各个变量不区别对待，而是考察它们之间的关系。
 - ▶ 描述和可视化
 - ▶ 关联规则分析
 - ▶ 主成分分析
 - ▶ 聚类分析等
- ▶ 有监督数据挖掘：建立根据一些变量来预测另一些变量的模型，前者被称为自变量，后者被称为因变量
 - ▶ 线性及广义线性回归
 - ▶ 神经网络
 - ▶ 决策树
 - ▶ 随机森林
 - ▶ 支持向量机等

有监督数据挖掘能从数据中获取深度细致的信息，应用非常广泛。

案例：谷歌流感趋势

谷歌推出“流感趋势”服务 可预测流感疫情

<http://tech.qq.com> 2008年11月12日17:46

[腾讯科技](#)

编译/长歌

[我要评论\(0\)](#)

腾讯科技讯 北京时间11月12日消息，据国外媒体报道，除了搜索网页之外，人们还可以利用谷歌来查找酒店或者书籍。而现在，谷歌推出的一项最新服务甚至能够帮助人们预防流感。

谷歌于美国当地时间本周二推出了一项名为“流感趋势”(Flu Trends，网址为：www.google.org/flutrends)的免费网络服务，该服务可以帮助人们了解自己所在地区（限美国境内）的流感病例爆发情况，从而提前采取预防措施，避免感染。“流感趋势”是通过谷歌关键词的监测来实现的。

它可以对“咳嗽”、“发烧”等与流感有关的关键词进行监测，并通过地图将这些的关键词被检索的趋势显示在其所对应的地区。相应的关键词密度越高、越频繁，该地区爆发流感的可能性就越大。由于这类关键词与流感之间存在着较强的相关性，因此该服务的可靠性比较高。

据悉，通过谷歌的“流感趋势”来对流感进行预测，其速度甚至要比美国疾病控制和预防中心（Centers for Disease Control and Prevention）还要快7~10天。例如，今年二月份，美国疾病控制和预防中心就曾表示，美国大西洋沿岸中部地区爆发了流感疫情，而谷歌的检索结果早在两周前就已经显示出了这种趋势。

美国疾病控制和预防中心的官员表示，谷歌“流感趋势”可以对其现有的监测工具起到很好的补充作用。（编译/长歌）

谷歌流感趋势

2009年2月，谷歌的一个研究小组在《自然》杂志上发表了论文，介绍了“谷歌流感趋势”。研究小组使用“咳嗽”、“发烧”等与流感相关的关键词的搜索频率为自变量，以疾病预防控制中心的数据为因变量，根据历史数据建立了统计模型。他们发现，可以通过监测相关关键词的变化趋势，追踪美国境内流感的传播趋势，而这一结果不依赖于任何医疗检查。谷歌的追踪结果很及时，而疾病控制中心则需要汇总大量医师的诊断结果才能得到一张传播趋势图，延时为一至两周。

TRACKING THE FLU

The relative frequency of flu-related keywords in Google searches closely tracks flu statistics in the US mid-Atlantic region as monitored by government officials.




《大数据时代》



谷歌流感趋势

然而，在2009年甲型H1N1流感（猪流感）流行的时候，谷歌流感趋势模型严重低估了流感的数量。谷歌工程师们对模型使用的关键词包进行了大幅度修改。



模型大幅度修改


Table 1. Comparison of relative query category volume in original and updated United States GFT models.

Query Category	Sample Query	Original Model Relative Category Volume	Updated Model Relative Category Volume
Symptoms of an influenza complication	[symptoms of bronchitis]	6%	11%
Influenza complication	[pnumonia]*	42%	6%
Specific influenza symptom	[fever]	6%	39%
General influenza symptoms	[early signs of the flu]	2%	30%
Cold/flu remedy	[robitussin]	12%	4%
Term for influenza	[influenza a]	<1%	3%
Antibiotic medication	[amoxicillin]	12%	0%
Related disease	[strep throat]	16%	<1%

- ▶ 原始模型含大约40个关键词，修改后模型含大约160个关键词
- ▶ 两个模型只有11个共同的关键词

谷歌流感趋势

好景不长。2013年1月，美国流感发生率达到峰值，谷歌流感趋势的估计比实际数据高两倍，这一不精确的估计再次引起了媒体的关注。



大数据，还是大错误？

2014-3-28 英国《金融时报》专栏作家蒂姆·哈福德

数据的规模很大，相对容易采集，而且可以实时地更新。

大数据的鼓吹者们提出了四个令人兴奋的论断，每一个都能从谷歌流感趋势的“成功”中得到“印证”：

1. 数据分析可以生成准确率惊人的结果；
2. 因为每一个数据点都可以被捕捉到，所以可以彻底淘汰过去抽样统计的方法；
3. 不用再寻找现象背后的原因，我们只需要知道两者之间有统计相关性就行了；
4. 不再需要科学的或者统计的模型，理论被终结了，数据已经大到可以自己说出结论。

教训：抽样偏差

我们感兴趣的是推断整个人群中的流感患病率，但在谷歌上进行搜索的群体可能代表不了整个人群。例如，在谷歌上进行搜索的群体中年龄比较大的人和儿童所占的比例可能低于其在整个人群中的比例。


教训：抽样偏差

《文学摘要》

The Literary Digest

NEW YORK

OCTOBER 31, 1936



1936 Roosevelt vs Landon

Topics of the day

LANDON, 1,293,669; ROOSEVELT, 972,897

Final Returns in The Digest's Poll of Ten Million Voters


Well, the great battle of the ballots in the Poll of ten million voters, scattered throughout the forty-eight States of the

lish National Committee purchased THE LITERARY DIGEST? And all types and varieties, including: "Have the Jews purchased

returned and let the people of the Nation draw their conclusions as to our accuracy. So far, we have been right in every Poll. Will we be right in the current Poll? That, as Mrs. Roosevelt said concerning the President's reelection, is in the 'lap of the gods.'

"We never make any claims before election but we respectfully refer you to the opinion of one of the most trusted citizens

盖洛普



教训：相关性 vs 因果性

不需要任何理论的纯粹的相关性分析方法，其结果往往是脆弱的。

谷歌流感趋势在2013年出错的一种解释是，2012年12月份的媒体上充斥着各种关于流感的骇人故事，看到这些报道之后，即使是健康的人也会跑到互联网上搜索相关的词汇。还有另外一种解释，就是谷歌对自己的搜索算法进行了修改，在人们输入病症的时候会自动推荐一些诊断结果，进而影响到了用户的搜索和浏览行为。

教训：相关性 vs 因果性

X	Y
冰淇淋销量	气温

or

X	Y
气温	冰淇淋销量

案例：人工智能选美比赛

Beauty.AI在2016年举办了第一届由机器评选的国际选美比赛。它希望通过深度学习人脸照片的方法来选出“美人”，考察的指标包括面部特征是否对称、皱纹的多少等。来自100多个国家的6000多个人提交了她们的照片。

 Lu Sophia Age: 18 Real age prediction: 13 Perceived age prediction: 15 AntiAging score: 2 PMPPL score: 1.3 RYNKL score: 1 MADIS score: 97 Symmetry Master score: 5.2	 Margeri Ottis Age: 27 Real age prediction: 23 Perceived age prediction: 23 AntiAging score: 7 PMPPL score: 1.2 RYNKL score: 3 MADIS score: 96 Symmetry Master score: 3.1	 Kerri Kinney Age: 26 Real age prediction: 18 Perceived age prediction: 16 AntiAging score: 8.5 PMPPL score: 1.2 RYNKL score: 5 MADIS score: 96 Symmetry Master score: 14.0
 Margarita Shestakova Age: 25 Real age prediction: 18 Perceived age prediction: 20 AntiAging score: 6.5 PMPPL score: 1.1 RYNKL score: 2 MADIS score: 96 Symmetry Master score: 1.3	 Evgeniya Miruk Age: 29 Real age prediction: 23 Perceived age prediction: 23 AntiAging score: 9 PMPPL score: 1.2 RYNKL score: 3 MADIS score: 97 Symmetry Master score: 5.2	

选美比赛

在44名获奖者中绝大多数都是白人，有几位是亚裔，而只有1位有黑皮肤。难道机器人不喜欢黑皮肤？

主要原因？

机器使用了有大量照片的数据集来训练选美算法，但是所使用的数据没有包含足够多的少数族裔。因此训练样本不能代表整个人群，存在抽样偏差。

尽管设计算法的团队没有将淡色皮肤当做美丽的标志，但是输入数据让机器做出这样的结论。

案例：用人工智能识别性取向

Kosinski and Wang (2017)的研究表明，深度神经网络能够比人类更精确地从人脸图像中检测出性取向。他们利用深度神经网络对公开约会网站上的大量照片进行了检测。给定单张人脸图像，机器判断异性恋还是同性恋的准确率对男性是81%，对女性是71%，而人判断的准确率分别只有61%和54%。若给出每人的五张脸部图像，机器判断的准确率对男女分别为91%和83%。

Kosinski and Wang (2017)指出，与性取向的产前荷尔蒙理论一致，同性恋的男性和女性倾向于有非典型性别的面部特征。他们认为，有关人脸图像的公开数据存在未经个人同意而直接被用于检测人们的性取向的可能，这将影响到人的隐私。

案例：用人工智能识别性取向

他们使用了什么样的数据，这些数据能支持研究结论吗？

Kosinski and Wang (2017)获取了约会网站上自称位于美国、年龄在18—40岁之间的36 630位男性和38 593位女性的照片，其中异性恋和同性恋的比例各占50%。假设总体是美国年龄在18—40岁之间的人群，该人群中的同性恋比例肯定远低于50%。此外，在约会网站上登记的人很可能不同于没有在约会网站上登记的人。例如，在约会网站上登记的已婚人士比例可能偏低。这里存在严重的抽样偏差，得出的结论也因而存在严重偏差。

案例：沃森肿瘤医疗系统

沃森是IBM的一个通过自然语言处理和机器学习，从非结构化数据中进行洞察的技术平台。2011年，沃森在美国最受欢迎的智力问答电视节目《危险边缘》中亮相，一举击败了人类智力竞赛冠军。



案例：沃森肿瘤医疗系统

IBM在医疗领域推广应用沃森平台，构建了沃森肿瘤医疗系统。它学习了美国顶级癌症中心纪念斯隆-凯特琳肿瘤中心（MSKCC）的大量肿瘤病例、300种以上的医学专业期刊、250本以上的医学书籍、超过1500万页的资料和临床指南，而且每月还学习最新的研究成果。

该系统根据医生输入的病人指标信息推荐个性化治疗方案。

案例：沃森肿瘤医疗系统

然而，这里也存在抽样偏差问题。实际用于统计建模的样本是MSKCC的肿瘤病例，而将沃森肿瘤医疗系统推广至中国、韩国、印度等地使用时，总体是这些地方的肿瘤病例。因此，沃森肿瘤医疗系统推荐的个性化治疗方案也会存在偏差。

案例：企业贷款信用风险

- ▶ 企业贷款违约的概率
- ▶ 一旦企业违约所带来的损失

如果能够很好地预测信用风险，银行能够根据信用风险的大小，

- ▶ 基于自身的风险偏好选择客户群体。
- ▶ 为不同的客户提供不同的贷款产品或不同的贷款利率。

两类错误

	判断为不违约者	判断为违约者
实际不会违约的企业	正确	失去潜在的业务和盈利机会
实际会违约的企业	产生大量的信用损失 (贷款的本金、利息等)	正确

最大程度地减少这两类错误，将会为银行带来可观的收益。

一致地诠释并管理风险：

- ▶ 对大量数据进行收集、存储和维护；
- ▶ 应用高级建模方法对信用风险进行建模；
- ▶ 对所使用的模型进行经常性的监测和修正。

巴塞尔协议就特别强调银行内部的信用风险管理。

数据收集

- ▶ 反映企业财务状况的年度财务报表
- ▶ 企业所处行业的总体情况
- ▶ 企业在所处行业中所占的位置
- ▶ 企业的市场地位
- ▶ 企业管理质量
- ▶ 企业管理层的风险偏好
- ▶ 审计报告的质量
- ▶ 企业开业时间
- ▶ 企业作为银行客户的时间

重点关注:

- ▶ 违约行为的确认;
- ▶ 有违约行为的企业在违约之前的各种信息。

- ▶ 数据中存在的自相矛盾和错误会导致任何建模努力付诸东流。
- ▶ 因为数据发生的频率比较低，例如财务报表多为年度数据，所以每一个数据点都是有价值的，需要尽一切努力保证数据的准确性，并尽可能减少丢弃数据。
- ▶ 数据清理需要自动过程与手动过程的有机结合：
 - ▶ 例如，需要详细验看资产负债表是否平衡、违约日期能否确定等。

建立丰富的信用风险模型

建立了分地区、分行业的一系列模型来预测风险类别，每一个风险类别都与一定范围的违约概率相联系。

验证模型的预测是否准确

对信用风险模型最重要的验证是通过收集企业实际违约情况的数据来实现的：

- ▶ 查验模型是否将实际信用水平低的企业归入风险比较高的类别；
- ▶ 查验模型预测为高风险的企业中是否实际违约率更高。

随着时间的推移，由于行业环境变化等因素，模型验证时会发现有信用风险模型的性能逐步下降，所以还需要及时对模型进行更新。

可以将新的企业的数据加入建模数据集，同时将时间过长的数据从建模数据集中去除，根据新的数据集更新模型。

案例：中国海关

- ▶ 2004年我国进出口贸易突破1万亿元人民币，成为世界第三大对外贸易国；2005年我国进出口贸易总额突破1.4万亿元人民币。
- ▶ 海关作为对外贸易的直接窗口，是连接国内外市场的桥梁，其重要作用也日益凸现。
- ▶ 同时，进出口环节的违规和走私活动更加频繁，海关面临的形势更加复杂，所承担的打击走私、征收关税、货物监管的任务也更加艰巨。
- ▶ 海关执法评估系统（Enforcement Assessment System，简称EAS）利用统计数据增强了海关管理和分析信息的能力。

数据来源

海关统计是**全口径统计**，所有进出口货物都需按《海关法》规定如实申报。海关数据有几大来源：

- ▶ 原始凭证
 - ▶ 《中华人民共和国海关进（出）口货物报关单》
 - ▶ 经海关核发的其他申报单证
- ▶ 外贸企业基本情况
 - ▶ 企业名称、企业资产、行业信息等
- ▶ 来自**银行、国税部门、港口等其他部委和行业部门的信息**
 - ▶ 外贸企业可能在某一个方面提供虚假信息，但是在整体上伪造信息的可能性非常低。
通过掌握全面的数据，海关极大提高了对进出口贸易管理和监督工作的效率。
- ▶ 国际来源，主要是韩国、日本等周边贸易大国或地区的海关数据

[应用一] 宏观：总体税收的预测

海关总体税收预测值 = 应征商品进口值预测值 × 应征商品综合税率预测值

以2005年第一季度后预测2005年全年税收为例。

- ▶ 使用时间序列方法预测2005年4至12月应征商品进口值，与前三个月的数值相加得到2005年全年应征商品进口值的预测值；
- ▶ 使用简单回归方法预测应征商品综合税率。

结果：若国际市场和国内经济稳定、相关外贸政策变动不大，2005年税收的预测值为5261亿元人民币。2005年海关实际税收额为5278亿元人民币，可见预测值非常准确。

[应用二] 中观：直属海关层面的分析



海关总署共有41个直属海关，进出不同直属海关的商品和数量不尽相同。例如，

- ▶ 广州海关、深圳海关进口的商品主要集中于电子类产品和仪器仪表，进出口商品总量不大，但相对税收却可能很高；
- ▶ 青岛海关、宁波海关进口的商品则主要集中于大宗散货类的产品，总量很大，但税收可能相对较少。

如果强调单一的评价标准，并不能够反映各海关真实的业绩。

海关税率结构的差异

以税率为横坐标，不同税率区间的商品进口金额百分比为纵坐标作图，可以清晰地看出不同直属海关的税率结构之间存在差异。




使用聚类分析

根据税率结构对直属海关进行聚类分析，可将直属海关分为10个不同的组，然后对比同组中不同直属海关绩效的优劣。

- ▶ 例如，可使用应征综合税率和实际征收税率的差异作为考核指标，如果同一组中大部分直属海关实际征收税率都与应征综合税率相差不大，但有一个直属海关实际征收税率显著高于应征综合税率，那么说明这个直属海关的管理绩效比较高。
- ▶ 再如，在同一组中比较各直属海关的通关时间，如果出现差别很大的情况，可以结合通关流程分析，及时发现不同直属海关在管理上的差距，整体提升海关的管理水平。

[应用三] 微观：进出口货物的异常波动

进出口商品的价格分布看似无规则，但如果按照来源地、尺寸、材料、交易时间等因素分类，可以看出同类商品的价格基本符合正态分布。



提高查验准确率

- ▶ 可以把商品细分到各类;
- ▶ 把该类中价格处于最低2.5%和最高2.5%的商品作为重点查验的对象。

这种有的放矢的查验比随机查验的准确率更高。

案例：意大利信息系统联盟

在意大利，信息系统联盟（CSI）在信息技术和远程通信领域代表了公共管理机构。

CSI为公众健康服务设计了决策支持系统，该系统回答了下列一些问题：

- ▶ 与去年相比，医疗开销增长了多少？哪类病人主要导致了这一增长？
- ▶ 在不同地区，各类疾病的医疗开销是怎样分布的？
- ▶ 不同年龄段患者的平均开销是怎样变化的？
- ▶ 哪类疾病需要患者支付的医疗开销最大？

- ▶ 在意大利，公众健康服务是由本地公众健康服务权威机构来管理的。在皮德蒙特高原就有22家独立的本地权威机构。
- ▶ CSI开发了商业智能系统，将22家权威机构的信息集中在一个数据仓库中。

- ▶ 该系统能够检查数据并为医生提供图形化的报告，这些报告向医生显示了针对不同性别、不同年龄段等患者的治疗方案分布，据此医生可以比较自己的治疗方案和其他医生的治疗方案。
- ▶ 该系统的另一个优势是让医生知道他们的信息正在被监视。药品公司经常主动向医生推广自己的新药，但药品价格并不总是合适的，医生知道他们的信息被监视，就会更加谨慎地开药。

CSI还能帮助回答诸如世界卫生组织（WHO）建议的高血压治疗方案是否被遵循的问题。

- ▶ CSI分析了所有患者近6个月的高血压特效药的使用情况。结果表明高血压的治疗占总开销的30%以上，这一比例是相当高的。
- ▶ 通过对4000名医生的聚类分析，CSI发现了一组没有遵守WHO指导方针的医生。
- ▶ 皮德蒙特高原地区决定安排相关的培训活动，向这些医生解释WHO的指导方针，找出他们没有遵守这些指导方针的原因。

案例：零售业

Staples是美国一家经营办公用品的连锁零售商店，拥有1100多家分店，年销售额近110亿美元。

- ▶ 它使用数据挖掘方法成功地管理各家分店。
- ▶ Staples采用的数据包括历史销售数据、客户（包括商户和家庭）的统计数据、分店所处的地段特征及该地段的竞争水平等。

- ▶ Staples每周收集并分析800多万个交易数据，为1100多家分店进行每周和每日的销售预测。
- ▶ 这些数据还被用于公司的其它事务，如季度销售预测、用人计划、存货管理、年度预算等。
- ▶ Staples还使用数据挖掘为新的分店选址，通过预测近500家预选店址未来三年的销售额，选择最优的店址。因为关闭一家分店的成本大约在50万到100万美金之间，通过数据挖掘避免错误的选址决策已经为公司节省了数百万美元。

案例：麻省理工的十亿级价格项目

麻省理工的十亿级价格项目（MIT Billion Prices Project）是一个学术项目，每天从全世界几百家在线零售商收集价格数据，用于经济研究。




麻省理工的十亿级价格项目

以消费者价格指数（CPI）的计算为例，传统的方法需要统计部门的工作人员从线下收集各类商品的价格数据，不仅费时费力，而且所得结果相对滞后。而线上数据的收集具有费用低、速度快、考察范围广以及商品信息更为全面的优势，是传统计算方法的有利补充。

麻省理工的十亿级价格项目

以阿根廷2007至2015年的CPI数据为例。一个很明显的事实是，官方公布的CPI数据并没有真实反映出该国的物价变化。而利用从线上收集的价格数据计算出的CPI更贴近人们对物价的真实感受。




总结：数据挖掘带来的收益

数据分析能力往往成为一个组织的核心竞争力。

- ▶ 数据挖掘能够帮助满足客户需求、降低风险、最大化收益、简化管理流程、优化资源配置等。
- ▶ 机构使用数据挖掘技术获取超过10倍的直接投资回报的案例司空见惯。
- ▶ 数据挖掘还往往带来很多无法直接度量的效果，如信息流动的通畅、管理监督能力的提升等。

CRISP-DM (CRoss-Industry Standard Process for Data Mining, 数据挖掘的跨行业标准过程)



针对数据挖掘过程中与数据准备、建模、模型评估相关的部分，SAS公司提出了SEMMA方法论，将这些部分的过程分为抽样（Sample）、探索（Explore）、修整（Modify）、建模（Model）、评估（Assess）几个阶段。

- ▶ 抽样。从数据集中抽取具有代表性的样本，样本应该大到不丢失重要的信息，小到能够便于操作。创建三个数据子集：
 - ▶ 训练数据，用于拟合各模型；
 - ▶ 验证数据，用于评估各模型并进行模型选择，避免过度拟合；
 - ▶ 测试数据，用于对模型的普适性形成真实的评价。

- ▶ 探索：使用可视化方法或主成分分析、因子分析、聚类等统计方法对数据进行探索性分析，发现未曾预料的趋势和异常情况，对数据形成初步理解，寻求进一步分析的思路。
- ▶ 修整
 - ▶ 生成和转换变量
 - ▶ 发现异常值
 - ▶ 变量选择等
- ▶ 建模：搜寻能够可靠地预测因变量的数据组合，具体而言是指采用哪些观测、使用哪些自变量能够可靠地预测因变量。
- ▶ 评估：评估模型的实用性、可靠性和效果。