

Data Mining and Applications

数据挖掘与应用

第3章：缺失数据

缺失数据模式和缺失数据机制

- 缺失数据模式

- 缺失数据机制

缺失数据机制对数据分析的影响

- 最简单情形

- 单变量缺失

- 一般缺失模式

缺失值插补

- 显式建模

- 隐式建模

缺失值插补和分析示例：纽约空气质量

两类缺失值

缺失值可分为两类：

- ▶ 第一类：这个值实际存在但是没有被观测到。

- ▶ 例如，顾客拒绝提供收入状况；

预测或插补未观测的值的数据分析是有意义的。

- ▶ 第二类：这个值实际就不存在。

- ▶ 例如，在考察顾客购买的洗发水品牌时，如果某位顾客根本没有购买任何洗发水，那么这位顾客购买的洗发水品牌缺失。

- ▶ 再如，对于没有在淘宝上购买过东西的顾客，其在淘宝上的消费记录缺失。

插补未观测的值是无意义的，根据是否缺失对数据进行分层的分析才更加合适。

我们将关注第一类情形。

在缺失数据分析中，需要将指示数据中变量是否缺失的那些指示变量也当作随机变量。

- ▶ 定义矩阵 $\mathcal{Y} = (y_{ij})_{N \times K}$ 表示不含缺失值的数据集，其中， N 代表个体数， K 代表变量数。
- ▶ 定义缺失指示变量 m_{ij} ： $m_{ij} = 1$ 表示 y_{ij} 缺失， $m_{ij} = 0$ 表示 y_{ij} 被观测到。由缺失指示变量组成的矩阵为 $\mathcal{M} = (m_{ij})_{N \times K}$ ， $\mathcal{M}$ 给出了缺失数据的模式。

缺失数据模式

▶ 单变量缺失, 例如: $\mathcal{M} = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \end{pmatrix}$

▶ 单调缺失模式, 例如: $\mathcal{M} = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 1 \end{pmatrix}$

▶ 一般缺失模式, 例如: $\mathcal{M} = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \end{pmatrix}$

缺失数据机制指的是 $\mathcal{M}$ 给定 $\mathcal{Y}$ 的条件分布 $f(\mathcal{M}|\mathcal{Y}, \phi)$, 其中 ϕ 是未知参数。它在缺失数据的分析中起着至关重要的作用。

缺失数据机制

- ▶ **完全随机缺失** (Missing Completely at Random, MCAR) :
 $f(\mathcal{M}|\mathcal{Y}, \phi) = f(\mathcal{M}|\phi)$ 对任意 $\mathcal{Y}$ 和 ϕ 都成立,
即缺失指示矩阵不依赖于任何数据的值。任何一个个体的任何一个变量是否缺失是一个完全随机的事件, 就像由扔硬币决定一样 (硬币出现正面的概率由 ϕ 给出, 不一定等于0.5)。
- ▶ **随机缺失** (Missing at Random, MAR) :
令 $\mathcal{Y}^{obs}$ 表示 $\mathcal{Y}$ 中观测到的值, $\mathcal{Y}^{mis}$ 表示 $\mathcal{Y}$ 中缺失的值,
 $f(\mathcal{M}|\mathcal{Y}, \phi) = f(\mathcal{M}|\mathcal{Y}^{obs}, \phi)$ 对任意 $\mathcal{Y}$ 和 ϕ 都成立,
即缺失指示矩阵只依赖于已观测数据 $\mathcal{Y}^{obs}$ 的真实值, 不依赖于缺失数据 $\mathcal{Y}^{mis}$ 的真实值。
- ▶ **非随机缺失** (Not Missing at Random, NMAR) :
缺失指示矩阵依赖于缺失数据 $\mathcal{Y}^{mis}$ 的真实值。

假设

我们假设 $(y_{i1}, \dots, y_{iK}, m_{i1}, \dots, m_{iK})$ 是随机变量 $(Y_1, \dots, Y_K, M_1, \dots, M_K)$ 的独立同分布的样本。

示例：最简单情形

最简单的数据结构：假设数据是单个随机变量 Y 的样本。某些个体的值缺失， M 为指示 Y 是否缺失的变量。

$\mathcal{Y} = (y_1, \dots, y_N)^T$ ，其中 y_i 为个体 i 的取值。

记 $\mathcal{M} = (m_1, \dots, m_N)^T$ 为相应的缺失指示向量。

示例：最简单情形

$\mathcal{Y}$ 和 $\mathcal{M}$ 的联合概率分布为

$$\begin{aligned} f(\mathcal{Y}, \mathcal{M} | \theta, \phi) &= \prod_{i=1}^N f(y_i, m_i | \theta, \phi) \\ &= \prod_{i=1}^N f(y_i | \theta) \prod_{i=1}^N f(m_i | y_i, \phi), \end{aligned}$$

其中 θ 为 Y 的概率分布的参数，是统计推断的主要目标。

- ▶ 完全随机缺失（等价于随机缺失）：
 $f(M|Y, \phi) = f(M|\phi)$ 。
- ▶ 非随机缺失： $f(M|Y, \phi)$ 依赖于 Y 。

示例：最简单情形

假设 $y_1, \dots, y_N$ 中 r 个值被观测到， $N - r$ 个值缺失。


是否可以将观测到的 r 个值当作样本量为 r 的随机样本，对 Y 的概率分布的参数 θ 做推断？

例如，假设 Y 满足分布 $N(\mu, \sigma^2)$ ，观测到的 r 个值的样本均值为 $\bar{y}_r$ ，样本标准差为 s 。是否可以用 $\bar{y}_r$ 来估计 μ ，而将标准误差估计为 $s/\sqrt{r}$ ？

示例：最简单情形

假设 $\mu = 0, \sigma^2 = 1, N = 1000$ 。

$y_1, \dots, y_{1000}$ 的直方图如下：




这组数据的样本均值为-0.00018。

示例：最简单情形

完全随机缺失：假设 $Pr(M = 1|Y, \phi) = 0.5$ 。

观测到的 r 个值 ($r = 482$) 的直方图如下：




这组数据的样本均值为0.025。

示例：最简单情形

非随机缺失：假设 $Pr(M = 1|Y, \phi) = \Phi(-2.05Y)$ ，其中 Φ 为标准正态分布的分布函数。

观测到的 r 个值（ $r = 495$ ）的直方图如下：



这组数据的样本均值为0.728。

示例：最简单情形

我们也可以通过似然函数的推导得出：

1. 在随机缺失情形下，基于已观测值对总体参数做推断是无偏的。
2. 在非随机缺失情形下，基于已观测值对总体参数做推断是有偏的。

示例：最简单情形

$$\begin{aligned}\text{似然函数: } L(\theta, \phi) &= f(\mathcal{Y}^{obs}, \mathcal{M}|\theta, \phi) = \int f(\mathcal{Y}^{obs}, \mathcal{Y}^{mis}, \mathcal{M}|\theta, \phi) d\mathcal{Y}^{mis} \\ &= \int \prod_{m_i=0} f(y_i|\theta) \prod_{m_i=1} f(y_i|\theta) \prod_{m_i=0} f(m_i|y_i, \phi) \prod_{m_i=1} f(m_i|y_i, \phi) \prod_{m_i=1} dy_i\end{aligned}$$

► 如果缺失机制是完全随机缺失（等价于随机缺失），那么

$$\begin{aligned}L(\theta, \phi) &= \prod_{m_i=0} f(y_i|\theta) \prod_{i=1}^n f(m_i|\phi) \prod_{m_i=1} \int f(y_i|\theta) dy_i \\ &= \prod_{m_i=0} f(y_i|\theta) \prod_{i=1}^n f(m_i|\phi)\end{aligned}$$

根据似然函数对 θ 进行推断时,只需要关注

$$\prod_{m_i=0} f(y_i|\theta) = f(\mathcal{Y}^{obs}|\theta)。$$

示例：最简单情形

$$\begin{aligned}\text{似然函数: } L(\theta, \phi) &= f(\mathcal{Y}^{obs}, \mathcal{M}|\theta, \phi) = \int f(\mathcal{Y}^{obs}, \mathcal{Y}^{mis}, \mathcal{M}|\theta, \phi) d\mathcal{Y}^{mis} \\ &= \int \prod_{m_i=0} f(y_i|\theta) \prod_{m_i=1} f(y_i|\theta) \prod_{m_i=0} f(m_i|y_i, \phi) \prod_{m_i=1} f(m_i|y_i, \phi) \prod_{m_i=1} dy_i\end{aligned}$$

► 如果缺失机制是非随机缺失，那么

$$L(\theta, \phi) = \prod_{m_i=0} f(y_i|\theta) \prod_{m_i=0} f(m_i|y_i, \phi) \prod_{m_i=1} \int f(y_i|\theta) f(m_i|y_i, \phi) dy_i$$

根据似然函数对 θ 进行推断时,就不能只关注
 $\prod_{m_i=0} f(y_i|\theta) = f(\mathcal{Y}^{obs}|\theta)$ 。

示例：最简单情形

遗憾的是，在实际数据分析中，我们并不知道缺失机制是完全随机缺失、随机缺失还是非随机缺失；对于非随机缺失的情形，我们也无法根据观测到的数据推断缺失指示值与变量真实值之间的关系。我们需要尽可能使关于缺失机制的假设更加可信。

示例：单变量缺失

考察四个变量： Y_1 — 性别； Y_2 — 教育程度； Y_3 — 职业； Y_4 — 收入。

假设 Y_1 、 Y_2 和 Y_3 对所有个体都观测到，但 Y_4 对某些个体没有观测到。

只需要定义一个缺失数据指示变量 M ，当 Y_4 缺失时 M 取值为1，当 Y_4 观测到时 M 取值为0。

假设所有个体之间相互独立。

示例：单变量缺失

- ▶ 完全随机缺失： $Pr(M|Y_1, Y_2, Y_3, Y_4; \phi) = Pr(M|\phi)$ 。
收入是否缺失完全是随机的，与性别、教育程度、职业和收入本身的值都无关。
- ▶ 随机缺失：
 $Pr(M|Y_1, Y_2, Y_3, Y_4; \phi) = Pr(M|Y_1, Y_2, Y_3; \phi)$ 。
人们是否透露收入与性别、教育程度、职业有关系。尽管收入缺失的比例在不同性别、教育程度、职业的人群之间有差异，但是在每一类人群内收入是否缺失与收入本身的值无关。
- ▶ 非随机缺失： $Pr(M|Y_1, Y_2, Y_3, Y_4; \phi)$ 依赖于 Y_4 。
在控制了性别、教育程度、职业这些因素之后，收入是否缺失还依赖于收入本身的值。

示例：单变量缺失

一般而言，假设 $Y_1, \dots, Y_{K-1}$ 对所有个体都观测到，但 Y_K 对某些个体没有观测到。

当数据是否缺失不受数据采集者的控制时，如果 $Y_1, \dots, Y_{K-1}$ 包含既能预测 Y_K 的值又能预测 Y_K 缺失概率（即预测 M 的值）的所有重要变量，那么在分析中包含这些变量能减少 M 与 Y_K 之间的关联，随机缺失假设会更加可信。

示例：单变量缺失

关于缺失机制的假设的重要性依赖于分析的目标。

- (一) 如果分析目标有关 $Y_1, \dots, Y_{K-1}$ 的边缘分布, 那么 Y_K 的缺失机制无关紧要。
- (二) 如果分析目标有关 Y_K 给定 $Y_1, \dots, Y_{K-1}$ 的条件分布, 那么当 Y_K 缺失的机制是完全随机缺失或随机缺失时, 可以使用完整观测到的个体的数据进行分析。

示例：单变量缺失

定义 $\mathcal{Y}_j = (y_{1,j}, \dots, y_{N,j})^T$, $j = 1, \dots, K$ 。

给定 $\mathcal{Y}_1, \dots, \mathcal{Y}_{K-1}$, $\mathcal{Y}_K$ 和 $\mathcal{M}$ 的联合分布为

$$\begin{aligned} & f(\mathcal{Y}_K, \mathcal{M} | \mathcal{Y}_1, \dots, \mathcal{Y}_{K-1}, \theta, \phi) \\ &= \prod_{i=1}^N f(y_{i,K} | y_{i,1}, \dots, y_{i,K-1}, \theta) \prod_{i=1}^N f(m_i | y_{i,1}, \dots, y_{i,K-1}, y_{i,K}, \phi). \end{aligned}$$

其中 θ 为给定 $Y_1, \dots, Y_{K-1}$ 时 Y_K 的概率分布中的参数，是统计推断的主要目标。

示例：单变量缺失

似然函数: $L(\theta, \phi) = f(\mathcal{Y}_K^{obs}, \mathcal{M} | \mathcal{Y}_1, \dots, \mathcal{Y}_{K-1}, \theta, \phi)$

$$\begin{aligned} &= \int \prod_{m_i=0} f(y_{i,K} | y_{i,1}, \dots, y_{i,K-1}, \theta) \prod_{m_i=1} f(y_{i,K} | y_{i,1}, \dots, y_{i,K-1}, \theta) \\ &\quad \prod_{m_i=0} f(m_i | y_{i,1}, \dots, y_{i,K-1}, y_{i,K}, \phi) \prod_{m_i=1} f(m_i | y_{i,1}, \dots, y_{i,K-1}, y_{i,K}, \phi) \prod_{m_i=1} dy_{i,K} \end{aligned}$$

► 如果缺失机制是完全随机缺失或随机缺失，那么

$$\begin{aligned} L(\theta, \phi) &= \prod_{m_i=0} f(y_{i,K} | y_{i,1}, \dots, y_{i,K-1}, \theta) \prod_{i=1}^n f(m_i | y_{i,1}, \dots, y_{i,K-1}, \phi) \\ &\quad \prod_{m_i=1} \int f(y_{i,K} | y_{i,1}, \dots, y_{i,K-1}, \theta) dy_{i,K} \\ &= \prod_{m_i=0} f(y_{i,K} | y_{i,1}, \dots, y_{i,K-1}, \theta) \prod_{i=1}^n f(m_i | y_{i,1}, \dots, y_{i,K-1}, \phi) \end{aligned}$$

根据似然函数对 θ 进行推断时,只需要关注

$$\prod_{m_i=0} f(y_{i,K} | y_{i,1}, \dots, y_{i,K-1}, \theta).$$

示例：单变量缺失

似然函数: $L(\theta, \phi) = f(\mathcal{Y}_K^{obs}, \mathcal{M} | \mathcal{Y}_1, \dots, \mathcal{Y}_{K-1}, \theta, \phi)$

$$\begin{aligned} &= \int \prod_{m_i=0} f(y_{i,K} | y_{i,1}, \dots, y_{i,K-1}, \theta) \prod_{m_i=1} f(y_{i,K} | y_{i,1}, \dots, y_{i,K-1}, \theta) \\ &\quad \prod_{m_i=0} f(m_i | y_{i,1}, \dots, y_{i,K-1}, y_{i,K}, \phi) \prod_{m_i=1} f(m_i | y_{i,1}, \dots, y_{i,K-1}, y_{i,K}, \phi) \prod_{m_i=1} dy_{i,K} \end{aligned}$$

► 如果缺失机制是非随机缺失，那么

$$\begin{aligned} L(\theta, \phi) &= \prod_{m_i=0} f(y_{i,K} | y_{i,1}, \dots, y_{i,K-1}, \theta) \prod_{m_i=0} f(m_i | y_{i,1}, \dots, y_{i,K-1}, y_{i,K}, \phi) \\ &\quad \prod_{m_i=1} \int f(y_{i,K} | y_{i,1}, \dots, y_{i,K-1}, \theta) f(m_i | y_{i,1}, \dots, y_{i,K-1}, y_{i,K}, \phi) dy_{i,K} \end{aligned}$$

根据似然函数对 θ 进行推断时,就不能只关注

$$\prod_{m_i=0} f(y_{i,K} | y_{i,1}, \dots, y_{i,K-1}, \theta).$$

示例：单变量缺失

- (三) 如果分析目标有关 Y_K 的边缘分布，那么使用完整观测到的个体的数据进行分析通常是有偏的，除非 Y_K 缺失的机制是完全随机缺失。

示例：单变量缺失

$$Y_1 = \begin{cases} 1 & \text{女} \\ 0 & \text{男} \end{cases} \quad Y_2 = \begin{cases} 1 & \text{大学及以上} \\ 0 & \text{大学以下} \end{cases} \quad Y_3 : \text{收入}$$

假设MAR, Y_1 和 Y_2 取值不同的每组在总体中各占1/4。具体如下：

Y_1	Y_2	$E(Y_3 y_1, y_2)$	$Pr(M = 0 y_1, y_2)$
0	0	1400	0.9
0	1	5000	0.8
1	0	1600	0.95
1	1	4800	0.6

► Y_3 的总体均值为 $E(Y_3) = \frac{1}{4}(1400 + 5000 + 1600 + 4800) = 3200$ 。

► 在大样本情况下，使用完整观测的数据计算出的 Y_3 的均值

$$\begin{aligned} & \frac{0.9}{0.9 + 0.8 + 0.95 + 0.6} \times 1400 + \frac{0.8}{0.9 + 0.8 + 0.95 + 0.6} \times 5000 \\ & + \frac{0.95}{0.9 + 0.8 + 0.95 + 0.6} \times 1600 + \frac{0.6}{0.9 + 0.8 + 0.95 + 0.6} \times 4800 = 2972.3 \end{aligned}$$

是有偏的。

示例：单变量缺失

- 如果各组缺失比例都比较接近，那么使用完整观测所得出的推断偏差较小。例如，若四组的缺失比例分别为0.8、0.85、0.9和0.95，那么使用完整观测的数据计算出的 Y_3 的均值

$$\begin{aligned} & \frac{0.8}{0.8 + 0.85 + 0.9 + 0.95} \times 1400 + \frac{0.85}{0.8 + 0.85 + 0.9 + 0.95} \times 5000 \\ & + \frac{0.9}{0.8 + 0.85 + 0.9 + 0.95} \times 1600 + \frac{0.95}{0.8 + 0.85 + 0.9 + 0.95} \times 4800 = 3248.6 \end{aligned}$$

- 如果每组 Y_3 的总体均值比较接近，那么使用完整观测所得出的推断偏差也较小。例如，若四组的 Y_3 的总体均值分别为3050、3150、3250、3350，那么使用完整观测的数据计算出

$$\begin{aligned} & \frac{0.9}{0.9 + 0.8 + 0.95 + 0.6} \times 3050 + \frac{0.8}{0.9 + 0.8 + 0.95 + 0.6} \times 3150 \\ & + \frac{0.95}{0.9 + 0.8 + 0.95 + 0.6} \times 3250 + \frac{0.6}{0.9 + 0.8 + 0.95 + 0.6} \times 3350 = 3188.5 \end{aligned}$$

示例：单变量缺失

- ▶ 如果 Y_K 是随机缺失的，可以使用完整观测的个体对 Y_K 给定 $Y_1, \dots, Y_{K-1}$ 的条件分布进行建模，再将此模型用于插补未完整观测的个体的 Y_K 的值。使用这些插补值和已观测到的 Y_K 的值可以对 Y_K 的边缘分布进行分析。（参看后面“缺失值插补：显示建模”部分）

一般缺失模式下的完整观测分析

通常情况下，会有多于一个变量存在缺失值。

完整观测分析只使用所有变量都观测到的个体的数据。这种方法
的优点在于：

- ▶ 简单。将未完整观测的数据去掉之后，我们可以不加修改地应用各种统计分析方法。
- ▶ 各个统计量之间具有兼容性，因为它们都基于同样的样本计算而得。例如，使用完整观测所得的多个变量之间的协方差矩阵是正定的。

缺点在于：

- ▶ 由样本量减少带来的精度损失。
- ▶ 可能存在偏差，其偏差大小依赖于分析目标和缺失数据机制。

一般缺失模式下的完整观测分析

情形一：设分析目标是某个变量的边缘分布且该变量存在缺失值。

1. 如果是否完整观测是完全随机的，那么通过完整观测分析进行推断是无偏的。
2. 如果是否完整观测不是完全随机的，那么完整观测的个体不是所有个体的随机样本，通过完整观测分析进行推断会有偏差。偏差的大小依赖于
 - (1) 未完整观测的个体的比例；
 - (2) 对该变量而言，完整观测的个体和未完整观测的个体之间差异的大小。

当未完整观测的个体的比例比较低或者完整观测的个体和未完整观测的个体之间差异不大时，可以使用完整观测分析。

一般缺失模式下的完整观测分析

情形二：设分析目标是 Y_K 给定 $Y_1, \dots, Y_{K-1}$ 的条件分布且该条件分布的模型指定正确。

1. 如果给定 $Y_1, \dots, Y_{K-1}$ ，完整观测的概率不依赖于 Y_K ，那么通过完整观测分析进行推断是无偏的。这包括 $Y_1, \dots, Y_{K-1}$ 中某个变量是否缺失与该变量真实值有关的非随机缺失的情形。
2. 如果给定 $Y_1, \dots, Y_{K-1}$ 之后，完整观测的概率仍然依赖于 Y_K ，那么通过完整观测分析进行推断是有偏的。

这两个结论可以通过对似然函数的推导得到。

一般缺失模式下的完整观测分析

对于估计某个变量边缘分布的单维分析而言，完整观测分析比较浪费，因为对该变量有观测值但对其他变量有缺失值的那些个体也被忽略了。在有大量变量的数据集中，这种精度损失尤为严重。

例如，假设有20个变量，每个变量独立地有10%的比例缺失，那么完整观测个体的期望比例为 $(1 - 0.1)^{20} \approx 0.12$ ；对单维分析而言，有观测值的个体的比例为 $(1 - 0.1) = 0.9$ ；完整观测个体占有观测值的个体的比例仅为 $0.12/0.9 = 13\%$ 。

一般缺失模式下的可用观测分析

可用观测分析使用分析目标涉及的所有变量都观测到的个体的数据。例如，在估计某个变量的边缘分布时，使用所有对该变量有观测值的个体；在估计两个变量之间协方差的时候，使用所有对这两个变量都有观测值的个体；在估计 Y_K 给定 $Y_1, \dots, Y_{K-1}$ 的条件分布时，使用所有对这 K 个变量都有观测值的个体；等等。

缺点：由于不同分析使用的样本不同，导致分析结果不兼容。例如，通过可用观测分析获得的多个变量之间的协方差矩阵可能不是正定的。

缺失值插补

在估计变量 Y_K 的边缘分布或 Y_K 与其他变量的关系时，完整观测分析和可用观测分析都没有用到 Y_K 缺失的那部分个体的数据。

如果对 Y_K 缺失的个体，观测到另外一些与 Y_K 高度相关的变量的值，可以考虑使用这些变量预测缺失的 Y_K 的值，并在与 Y_K 相关的分析中使用这些插补值。

常用的缺失值插补方法都假设缺失数据机制是完全随机缺失或者随机缺失。如果这一假设成立，插补缺失值可以避免样本量的损失，提高推断的精度。

插补方法主要分为两大类：

1. 显式建模：使用正式的统计模型，因而假设是显式的。
2. 隐式建模：暗含着模型的插补算法，假设是隐性的，需要仔细分析这些假设是否合理。

显式建模插补的合理方案

假设 Y_1 和 Y_2 满足二元正态分布， Y_1 完全被观测到， Y_2 对某些个体缺失，缺失机制为随机缺失。

假设使用 Y_2 被观测到的个体进行分析（完整观测分析）可得：

- ▶ Y_2 的样本均值为 $\bar{y}_2$ ，样本方差为 $\tilde{\sigma}_2^2$ 。
- ▶ Y_2 对 Y_1 做线性回归时，所得的截距为 $\tilde{\alpha}_{2|1}$ ，斜率为 $\tilde{\beta}_{2|1}$ ，残差方差为 $\tilde{\sigma}_{2|1}^2$ 。

考虑如下四种对 Y_2 进行插补的方法：

- ▶ 无条件均值：使用 $\bar{y}_2$ 来插补每一个缺失的 Y_2 的值。
- ▶ 无条件抽样：从 $N(\bar{y}_2, \tilde{\sigma}_2^2)$ 中抽样来插补缺失的 Y_2 的值。
- ▶ 条件均值：使用 $\tilde{\alpha}_{2|1} + \tilde{\beta}_{2|1}y_{i,1}$ 来插补缺失的 Y_2 的值。
- ▶ 条件抽样：从 $N(\tilde{\alpha}_{2|1} + \tilde{\beta}_{2|1}y_{i,1}, \tilde{\sigma}_{2|1}^2)$ 中抽样来插补缺失的 Y_2 的值。

插补：显式建模示例

使用插补后的数据来估计如下四个参数：

- ▶ Y_2 的均值 μ_2 。
- ▶ Y_2 的方差 σ_2^2 。
- ▶ Y_2 对 Y_1 的回归系数 $\beta_{2|1}$ 。
- ▶ Y_1 对 Y_2 的回归系数 $\beta_{1|2}$ 。

参数估计的大样本偏差的情况见下表。

方法	μ_2	σ_2^2	$\beta_{2 1}$	$\beta_{1 2}$
无条件均值	有偏	有偏	有偏	有偏
无条件抽样	有偏	有偏	有偏	有偏
条件均值	0	有偏	0	有偏
条件抽样	0	0	0	0

只有条件抽样才能对所有参数产生一致的估计。

回归中自变量缺失的情形

上表中最后一列对应于在自变量存在缺失的情形下对回归系数进行推断。

当自变量中有一些缺失而另一些被观测到时，通常在插补自变量的缺失值时都会考虑到其他自变量的已观测值。但一个问题是：
在插补自变量的缺失值时是否也需要考虑因变量的已观测值？

从表面看来，在插补自变量时考虑因变量的已观测值似乎不正确：在使用因变量预测自变量的缺失值之后，又根据所有自变量预测因变量，会形成循环。上表表明，根据因变量的已观测值使用条件均值插补确实会带来偏差。

回归中自变量缺失的情形

然而，因变量和自变量之间是相关的，如果在插补自变量的缺失值时不使用因变量的已观测值，我们隐含地做了如下假设：对于自变量缺失的那些观测，给定其他已观测的自变量，因变量和被插补的自变量是不相关的。这种假设和回归模型的假设相矛盾。

因此，在插补自变量的缺失值时我们需要考虑因变量的已观测值。根据因变量的已观测值使用条件抽样插补不会产生偏差。

单调缺失模式的显式建模

对于单调缺失模式而言，可以将含缺失值的变量进行排序，依次对它们进行插补。例如，对缺失数据模式

$$\mathcal{M} = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 1 \end{pmatrix},$$

首先根据估计的 Y_2 给定 Y_1 的条件概率分布进行随机抽样插补 Y_2 的缺失值，然后根据估计的 Y_3 给定 Y_1 和 Y_2 的条件概率分布进行随机抽样插补 Y_3 的缺失值，最后根据估计的 Y_4 给定 Y_1 、 Y_2 和 Y_3 的条件概率分布进行随机抽样插补 Y_4 的缺失值。

一般缺失模式的显式建模

对于非单调的一般缺失模式而言，常用的两种插补缺失值的方法如下。

1. 假设各个变量满足多元正态分布，使用马可夫链蒙特卡洛（Markov Chain Monte Carlo, MCMC）算法对数据进行插补。
2. 使用MICE（Multivariate Imputation by Chained Equations）方法。首先初始化缺失值的插补值，然后在含缺失值的变量中循环进行如下操作直至收敛：估计 Y_j 给定所有其他变量的条件概率分布，再根据这一分布通过随机抽样插补 Y_j 的缺失值。

多重插补 (Multiple Imputation)

若只对缺失值进行一次插补并将插补值当作实际观测值进行分析，则没有**考虑到插补值的不确定性**，会使得各种标准误差被低估。对缺失值进行多重插补可以解决这个问题。

多重插补 (Multiple Imputation)

步骤如下:

1. 首先, 对缺失值进行多次插补, 得到 K 个插补数据集 $\mathcal{D}_1, \dots, \mathcal{D}_K$ 。
2. 然后, 对每个插补数据集 $\mathcal{D}_k$ 分别进行分析, 获得对参数 θ 的点估计 $\hat{\theta}_k$ 以及对该点估计的方差的估计 W_k 。
3. 最后, 综合这些分析结果。
 - (1) θ 的点估计为 $\bar{\theta} = K^{-1} \sum_{k=1}^K \hat{\theta}_k$ 。
 - (2) 该点估计的方差的估计为 $T = \overline{W} + (1 + K^{-1})B$, 其中 $\overline{W} = K^{-1} \sum_{k=1}^K W_k$, $B = (K - 1)^{-1} \sum_{k=1}^K (\hat{\theta}_k - \bar{\theta})^2$ 。

插补：隐式建模

以下列出了一些常用的隐式建模插补方法。

1. Hot deck 插补: 从“相似”的个体的已观测值中抽样来插补缺失值。Hot deck插补在抽样调查中很常用，可能会使用很复杂的机制来选择“相似”的个体。
2. Cold deck 插补: 使用从外部来源来的常数替代缺失值。例如，使用前次抽样调查所得的数据值。
3. 综合法: 将多种插补方法综合起来应用。例如，将Hot deck插补与回归插补结合。

这些方法没有使用明显的模型，通常无法对它们的效果进行正式分析。

假设ch3_air.csv数据集记录了纽约1973年5月到9月每天如下表所示的信息（数据集摘自R中自带的airquality数据集，只保留了表中的4个变量）。

变量名	含义
Ozone	平均臭氧浓度
SolarR	太阳辐射强度
Wind	平均风速
Temp	最高温度