

Chapter 1

EM 算法

1.1 EM 算法

EM 算法全称是Expectation-Maximum Algorithm. 其主要目的是用于求MLE. 当数据含有缺失数据, 或者虽然没有缺失数据, 但是引进隐变量 (可以看成是缺失数据) 之后, 似然函数变得简单, 这时候, 使用EM 算法会使得MLE 求解变得简单。

首先我们来看一个例子。

例1.1.1 (基因连锁模型 (Rao, 1973)). 观测到197个动物, 根据其属性, 可以将这些动物分为4类, 而且模型假定这四类占的概率分别是:

$$\frac{1}{2} + \frac{\theta}{4}, \frac{1}{4}(1 - \theta), \frac{1}{4}(1 - \theta), \frac{\theta}{4}.$$

用一个表表示观测及概率分布:

125	18	20	34
$\frac{1}{2} + \frac{\theta}{4}$	$\frac{1}{4}(1 - \theta)$	$\frac{1}{4}(1 - \theta)$	$\frac{\theta}{4}$

Table 1.1: 基因连锁模型及观测

似然函数是:

$$\ell(\theta|X) \propto p(X|\theta) \propto \left(\frac{1}{2} + \frac{\theta}{4}\right)^{125} \left(\frac{1}{4}(1 - \theta)\right)^{18+20} \left(\frac{\theta}{4}\right)^{34} \propto (2 + \theta)^{125} (1 - \theta)^{18+20} (\theta)^{34}$$

θ 的极大似然估计是

$$\hat{\theta} = \arg \max_{\theta} \log \ell(\theta) = \arg \max_{\theta} [125 \log(2 + \theta) + (18 + 20) \log(1 - \theta) + 34 \log(\theta)].$$

求解 θ 可以使用 *Newton* 法。

现在考虑引进一个隐变量，将表 1.1.1 第一个格子分成两个格子，见下表：

$125 - x_2$	x_2	18	20	34
$\frac{1}{2}$	$\frac{\theta}{4}$	$\frac{1}{4}(1 - \theta)$	$\frac{1}{4}(1 - \theta)$	$\frac{\theta}{4}$

Table 1.2: 引进隐变量后，基因连锁模型及观测

如果隐变量(x_2) 知道了，那么似然函数是：

$$\ell(\theta) = (\theta)^{x_2+34}(1 - \theta)^{18+20},$$

这时候，可以很容易的求出

$$\hat{\theta} = \frac{x_2 + 34}{x_2 + 34 + 18 + 20}.$$

EM 算法就是一个迭代的方法，每一次迭代，将 x_2 填补出来，然后很容易的计算 $\hat{\theta}$ 。

1.1.1 EM 算法的推导

用 X 代表观测数据， Z 代表缺失数据（或者隐变量）， θ 是待估计的参数。观测数据的边缘分布是

$$P(X|\theta) = \sum_z P(X|Z, \theta)P(Z|\theta), \text{ 如果 } Z \text{ 是连续的，用积分代替求和.}$$

这时候，对数似然是

$$\begin{aligned} L(\theta) &= \log \left[\sum_z P(X|Z, \theta)P(Z|\theta) \right] \\ &= \log \left[\sum_z P(Z|X, \theta_n) \frac{P(X|Z, \theta)P(Z|\theta)}{P(Z|X, \theta_n)} \right] \\ &\geq \sum_z P(Z|X, \theta_n) \log \left[\frac{P(X|Z, \theta)P(Z|\theta)}{P(Z|X, \theta_n)} \right] \\ &\triangleq \ell(\theta|\theta_n) = Q(\theta, \theta_n) + C(\theta_n), \end{aligned} \tag{1.1}$$

where $Q(\theta, \theta_n) = E_{Z|X, \theta_n} \log P(X, Z|\theta)$, $C(\theta_n)$ 依赖于 X and θ_n , 但是是一个和 θ 无关的量。 Q 称为完全数据对数似然的期望。上面的不等式是因为 Jensen 不等式：对于任意的 convex function $f(x)$, 任意的概率测度 μ , 有

$$E_\mu(f(X)) \geq f(E_\mu(X)).$$

简单的证明：对于任意 x_0 , 存在 a, b , 使得 $f(x) \geq ax + b$, 且 $f(x_0) = ax_0 + b$. 现在取 $x_0 = E_\mu(X)$, 有 $E_\mu(f(X)) \geq aE_\mu(X) + b = f(E_\mu(X))$.

从上面的不等式可以得到如下性质：

1. $L(\theta) \geq \ell(\theta|\theta_n)$.

2.

$$\begin{aligned}\ell(\theta|\theta_n) &= \sum_z P(Z|X, \theta_n) \log \left[\frac{P(X|Z, \theta_n)P(Z|\theta_n)}{P(Z|X, \theta_n)} \right] \\ &= \sum_z P(Z|X, \theta_n) \log \left[\frac{P(X, Z|\theta_n)P(X|\theta_n)}{P(Z, X|\theta_n)} \right] \\ &= \sum_z P(Z|X, \theta_n) \log [P(X|\theta_n)] \\ &= \log P(X|\theta_n) = L(\theta_n)\end{aligned}$$

3.

$$\frac{dL(\theta)}{d\theta}|_{\theta=\theta_n} = \frac{d\ell(\theta|\theta_n)}{d\theta}|_{\theta=\theta_n} = \frac{dQ(\theta, \theta_n)}{d\theta}|_{\theta=\theta_n}. \quad (1.2)$$

上面性质的证明：

Proof. 因为式(1.1)中的 $C(\theta_n)$ 和 θ 无关，所以显然 $\frac{d\ell(\theta|\theta_n)}{d\theta}|_{\theta=\theta_n} = \frac{dQ(\theta, \theta_n)}{d\theta}|_{\theta=\theta_n}$.


$$\begin{aligned}\frac{dQ(\theta, \theta_n)}{d\theta} &= \frac{dE_{Z|X, \theta_n} \log P(X, Z|\theta)}{d\theta} \\ &= E_{Z|X, \theta_n} \left(\frac{d \log P(X, Z|\theta)}{d\theta} \right) \\ &= E_{Z|X, \theta_n} \left(\frac{dP(X, Z|\theta)}{d\theta} \frac{1}{P(X, Z|\theta)} \right) \\ &= E_{Z|X, \theta_n} \left(\frac{dP(X, Z|\theta)}{d\theta} \frac{1}{P(Z|X, \theta)P(X|\theta)} \right)\end{aligned}$$

所以，

$$\begin{aligned}\frac{dQ(\theta, \theta_n)}{d\theta}|_{\theta=\theta_n} &= E_{Z|X, \theta_n} \left(\frac{dP(X, Z|\theta)}{d\theta}|_{\theta=\theta_n} \frac{1}{P(Z|X, \theta_n)P(X|\theta_n)} \right) \\ &= \sum_z \frac{dP(X, Z|\theta)}{d\theta}|_{\theta=\theta_n} \frac{1}{P(X|\theta_n)} \\ &= \sum_z \frac{d[P(Z|X, \theta)P(X|\theta)]}{d\theta}|_{\theta=\theta_n} \frac{1}{P(X|\theta_n)} \\ &= \sum_z \left[\frac{d[P(Z|X, \theta)]}{d\theta}|_{\theta=\theta_n} P(X|\theta_n) + \frac{d[P(X|\theta)]}{d\theta}|_{\theta=\theta_n} P(Z|X, \theta_n) \right] \frac{1}{P(X|\theta_n)} \\ &= \sum_z \left[\frac{d[P(Z|X, \theta)]}{d\theta}|_{\theta=\theta_n} \right] + \frac{d[P(X|\theta)]}{d\theta}|_{\theta=\theta_n} \frac{1}{P(X|\theta_n)} \\ &= \frac{d[\log P(X|\theta)]}{d\theta}|_{\theta=\theta_n},\end{aligned}$$

the last equality holds because the first item in the last second expression is 0 by exchanging derivative and integral. $\square$

从上面的性质可以看出，(1) $\ell(\theta, \theta_n)$ 是 $L(\theta)$ 的一阶近似。(2) 任何使得 $\ell(\theta|\theta_n)$ 增大的 θ 将会使 $L(\theta_{n+1}) \geq L(\theta_n)$. EM 算法寻求 $\theta_{n+1} = \arg \max_{\theta} \ell(\theta|\theta_n)$.



$$\begin{aligned}
 \theta_{n+1} &= \arg \max_{\theta} \ell(\theta|\theta_n) \\
 &= \arg \max_{\theta} \sum_z P(Z|X, \theta_n) \log \left[\frac{P(X|Z, \theta)P(Z|\theta)}{P(Z|X, \theta_n)} \right] \\
 &= \arg \max_{\theta} \sum_z P(Z|X, \theta_n) \log \left[\frac{P(X, Z|\theta)}{P(Z|X, \theta_n)} \right] \\
 &= \arg \max_{\theta} \sum_z P(Z|X, \theta_n) \log [P(X, Z|\theta)] \\
 &= \arg \max_{\theta} E_{Z|X, \theta_n} \log [P(X, Z|\theta)]
 \end{aligned}$$

综上所述，从初始值 θ_n 出发，计算 θ_{n+1} 的具体步骤可以总结下面两部：

1. E 步：计算条件期望 $E_n(\theta) \triangleq E_{Z|X, \theta_n} \log P(X, Z|\theta)$ (完全似然的期望)
2. M 步：计算上一步所得期望的最大值点： $\theta_{n+1} = \arg \max_{\theta} E_n(\theta)$.

例1.1.2 (基因连锁模型 (续)). 前面已经介绍了基因连锁模型, 引进隐变量后, 观测及其概率分布见下表:

x_1	x_2	x_3	x_4	x_5
$125 - x_2$	x_2	18	20	34
$\frac{1}{2}$	$\frac{\theta}{4}$	$\frac{1}{4}(1 - \theta)$	$\frac{1}{4}(1 - \theta)$	$\frac{\theta}{4}$

Table 1.3: 引进隐变量后, 基因连锁模型及观测

完全似然为

$$f(\theta) = \theta^{x_2+x_5}(1-\theta)^{x_3+x_4}.$$

1. E 步: $E_{x_2|X, \theta_n}[(x_2 + x_5) \log \theta + (x_3 + x_4) \log(1 - \theta)] = (E(x_2|X, \theta_n) + x_5) \log \theta + (x_3 + x_4) \log(1 - \theta)$. 注意到 $x_2 \sim \text{Binomial}(x_1 + x_2, \frac{\theta}{2+\theta})$. 所以, $E_n(\theta) = ((x_1 + x_2) \frac{\theta_n}{2+\theta_n} + x_5) \log \theta + (x_3 + x_4) \log(1 - \theta)$.

2. M 步:

$$\theta_{n+1} = \arg \max_{\theta} E_n(\theta) = \frac{(x_1 + x_2) \frac{\theta_n}{2+\theta_n} + x_5}{(x_1 + x_2) \frac{\theta_n}{2+\theta_n} + x_5 + x_3 + x_4}$$

例1.1.3 (Gaussian Mixture Model). $x_i \sim_{i.i.d.} pN(\mu_1, \sigma_1^2) + (1 - p)N(\mu_2, \sigma_2^2), \mu_1 \neq \mu_2, i = 1, 2, \dots, n$.

数据的似然函数是:

$$\prod_i \left[p \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x_i - \mu_1)^2}{2\sigma_1^2}} + (1 - p) \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{(x_i - \mu_2)^2}{2\sigma_2^2}} \right]$$

这个似然函数很复杂, 现在引入缺失数据, $z_i = 1$ 代表数据来自第一类, $z_i = 2$ 代表数据来自于第二类。于是观测数据 x_i , 可以写成含有缺失数据的形式 (x_i, z_i) . 数据的抽样方式可以描述为如下过程:

(1) 独立的抽取 z_i , with Bernoulli distribution $P(z_i = 1) = p$. (2) 如果 $z_i = 1$, 则 x_i 来自于 $N(\mu_1, \sigma_1^2)$; 如果 $z_i = 2$, 则 x_i 来自于 $N(\mu_2, \sigma_2^2)$ 。

这样的抽样过程使得 x_i 的边缘分布就是一个 Gaussian mixture 分布。

在有了完全数据 (x_i, z_i) 后, 数据的似然函数是:

$$\ell(X, Z; \theta) = \prod_i \left[I_{z_i=1} \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x_i - \mu_1)^2}{2\sigma_1^2}} p + I_{z_i=2} \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{(x_i - \mu_2)^2}{2\sigma_2^2}} (1 - p) \right].$$

参数 $\theta = (p, \mu_1, \mu_2, \sigma_1^2, \sigma_2^2)$. 对数似然是

$$\begin{aligned}
\ell(X, Z; \theta) &= \sum_i \log \left[I_{z_i=1} \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x_i-\mu_1)^2}{2\sigma_1^2}} p + I_{z_i=2} \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{(x_i-\mu_2)^2}{2\sigma_2^2}} (1-p) \right] \\
&= \sum_i I_{z_i=1} \log \left[\frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x_i-\mu_1)^2}{2\sigma_1^2}} p \right] + I_{z_i=2} \log \left[\frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{(x_i-\mu_2)^2}{2\sigma_2^2}} (1-p) \right] \\
&= \sum_i I_{z_i=1} \left[-\frac{1}{2} \log(\sigma_1^2) - \frac{(x_i-\mu_1)^2}{2\sigma_1^2} + \log(p) \right] + I_{z_i=2} \left[-\frac{1}{2} \log(\sigma_2^2) - \frac{(x_i-\mu_2)^2}{2\sigma_2^2} + \log(1-p) \right] + C
\end{aligned}$$

E 步:

$$\begin{aligned}
&E(\ell(X, Z; \theta) | X; \theta_n) \\
&= \sum_i P(z_i = 1 | X, \theta_n) \left[-\frac{1}{2} \log(\sigma_1^2) - \frac{(x_i-\mu_1)^2}{2\sigma_1^2} + \log(p) \right] + P(z_i = 2 | X, \theta_n) \left[-\frac{1}{2} \log(\sigma_2^2) - \frac{(x_i-\mu_2)^2}{2\sigma_2^2} + \log(1-p) \right] + Cn
\end{aligned}$$

M 步:

上式是 θ 的函数, 分别对五个未知参数求导, 可得各个参数的更新:

(1) p 的更新: 对 $\sum_i P(z_i = 1 | X, \theta_n) [\log(p)] + P(z_i = 2 | X, \theta_n) [\log(1-p)]$ 关于 p 最优化, 可以得到对 p 的更新 $p^{(n+1)} = \sum_i P(z_i = 1 | X, \theta_n) / \sum_i [P(z_i = 1 | X, \theta_n) + P(z_i = 2 | X, \theta_n)]$.

(2) $(\mu_k, \sigma_k^2), k = 1, 2$ 的更新: 其实这是一个 *weighted least square* 问题,

$$\sum_i w_i^{(k)} \left[-\frac{1}{2} \log(\sigma_k^2) - \frac{(x_i - \mu_k)^2}{2\sigma_k^2} \right],$$

$$w_i^{(k)} = P(z_i = k | X, \theta_n).$$

分别对 μ_k, σ_k^2 求导, 可以得到对他们的更新: $\mu_k = \frac{\sum_i w_i^{(k)} x_i}{\sum_i w_i^{(k)}} \sigma_k^2 = \frac{\sum_i w_i^{(k)} (x_i - \mu_k)^2}{\sum_i w_i^{(k)}}$.

从上面的计算过程中, 可以看到, 整个过程需要计算的量是 $P(z_i = 1 | X, \theta_n)$. 注意到

$$\begin{aligned}
P(z_i = 1 | x_i, \theta_n) &= \frac{P(z_i = 1, x_i; \theta_n)}{f(x_i; \theta_n)} \\
&= \frac{f(x_i | z_i = 1; \theta_n) P(z_i = 1; \theta_n)}{\sum_k f(x_i | z_i = k; \theta_n) P(z_i = k; \theta_n)} \\
&= \frac{f(x_i | z_i = 1; \theta_n) p_n}{\sum_k f(x_i | z_i = k; \theta_n) p_n^{(k)}},
\end{aligned}$$

where $p_n^{(1)} = p_n, p_n^{(2)} = 1 - p_n$.