

Lecture 3: 缺失数据插补

- ##加载程序包
- library(mice)
- #mice是实现多重插补的程序包，我们将调用其中的mice和md.pattern函数。
- library(VIM)
- #VIM是展示数据缺失模式可视化的程序包，我们将调用其中的aggr函数。
- library(dplyr)
- #dplyr是数据处理的程序包，我们将调用其中的管道函数。

The Data

- ##读入数据，生成R数据框
- `Air <- read.csv ("F:/data/ch3_air.csv",
colClasses=rep("numeric",4))`
- #rep函数将字符串"numeric"重复4次得到一个长度为4的向量。
- #colClasses=rep("numeric",4) 指定4个变量的类型均为数值型。

- ##查看Air数据集各变量的基本情况
- summary(Air)
- #观察到Air的前两个变量Ozone和SolarR分别有37和7个缺失值

```
> ##查看Air数据集各变量的基本情况
```

```
> summary(Air)
```

Ozone	SolarR	wind	Temp
Min. : 1.00	Min. : 7.0	Min. : 1.700	Min. :56.00
1st Qu.: 18.00	1st Qu.:115.8	1st Qu.: 7.400	1st Qu.:72.00
Median : 31.50	Median :205.0	Median : 9.700	Median :79.00
Mean : 42.13	Mean :185.9	Mean : 9.958	Mean :77.88
3rd Qu.: 63.25	3rd Qu.:258.8	3rd Qu.:11.500	3rd Qu.:85.00
Max. :168.00	Max. :334.0	Max. :20.700	Max. :97.00
NA's :37	NA's :7		

- ##查看数据缺失模式
- md.pattern(Air)

```
> md.pattern(Air)
      wind Temp SolarR Ozone
111      1    1      1     1  0
35      1    1      1     0  1
5       1    1      0     1  1
2       1    1      0     0  2
      0    0      7    37 44
```

缺失模式中，1表示对应变量的观测到，0表示对应变量的缺失。
最左边列表示对应缺失模式的观测数，
最右边列表示对应缺失模式的缺失变量个数。
例如，有35个观测的Wind、Temp、SolarR这三个变量都被观测到，
而Ozone变量缺失，每个这样的观测有一个变量缺失。
最后一行表示对应每列的有缺失值的观测数。

```
> ##查看数据缺失模式
> md.pattern(Air)
      Wind Temp SolarR Ozone
111      1    1      1      1  0
35       1    1      1      0  1
5        1    1      0      1  1
2        1    1      0      0  2
      0    0      7     37 44
```

##将Air数据集的缺失情况可视化

```
aggr(Air,prop=T,numbers=T,col=c('white','grey'))
```



#aggr函数将数据缺失情况可视化呈现，

左图给出每个变量的缺失情况，右图给出每种缺失模式的情况。

prop=T指定左图纵坐标为缺失比例，

numbers=T指定右图显示对应缺失模式所占的比例。

col=c('white','grey')指定观测值和缺失值分别用白色和灰色表示。



##对Air数据集进行多重插补。

```
m <- 5
```

#指定插补重数为5。

```
mi_Air <- mice(Air,m)
```

#mice函数实现多重插补，插补后的数据存入mi_Air。

##对插补后的数据集work.mi_Air进行综合分析，

##估计Ozone和SolarR这两个变量的总体均值，并得到估计的标准误差。

```
with(mi_Air,lm(Ozone~1)) %>% pool() %>% summary()
```



```
> with(mi_Air, lm(Ozone~1)) %>% pool() %>% summary()
      estimate std.error statistic      df p.value
(Intercept) 40.90196   2.736312  14.94784  88.24816      0
```

- lm函数用于建立线性回归模型，
- 截距项的估计实际上就是对Ozone变量的总体均值的估计。
- with函数对mi_Air的每个插补数据集都进行回归分析。
- 使用管道函数“%”和pool函数对mi_Air中各个插补数据集的结果进行综合分析。
- 使用管道函数“%”和summary函数输出综合分析的结果，输出结果中，
- est为截距项（Intercept）的综合估计值，
- 也就是对Ozone变量的总体均值的综合估计；
- se为对Ozone变量的总体均值的综合估计的标准误差。