

第六章 重抽样方法

提纲

Bootstrap 估计的思想

基于 Jackknife 法的估计

基于 Bootstrap 法的置信区间估计

主要内容

本章主要讨论两种抽样方法，即 Bootstrap 法和 Jackknife 法。
通过这两种方法得到估计量的偏差，方差等估计。

- ✓ 基于 Bootstrap 法的估计
 - (1). Bootstrap 估计的思想
 - (2). 偏差的 Bootstrap 估计
 - (3). 估计量标准差的 Bootstrap 估计
- ✓ 基于 Jackknife 法的估计
 - (1). 偏差的 Jackknife 估计
 - (2). 估计量标准差的 Jackknife 估计
 - (3). Jackknife-after-Bootstrap 估计
- ✓ 基于 Bootstrap 法的置信区间估计

Bootstrap 估计的思想

自助法，也称 Bootstrap 方法，由 Efron 于 1979 年首次提出，此后发展了大量的关于 Bootstrap 方法的研究。

首先通过一个简单例子给出 Bootstrap 估计的直观理解。

设 $X_1, X_2, \dots, X_n$ 为来自总体分布 $F(x; \theta)$ 的样本，对于感兴趣参数 θ ，通常可采用极大似然估计或者矩估计等估计方法得到 θ 的估计 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 。

很多时候，我们不仅关心 θ 的估计 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 本身，同时也关心估计量的分布以及分布特征，比如 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 的均值 $E(\hat{\theta})$ 和方差 $\text{Var}(\hat{\theta})$ 。

Bootstrap 估计的思想

事实上, 一般情况下, 很难推导出 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 的分布, 进而得到估计量的均值和方差。

如果 $F(x; \theta)$ 分布形式已知, 可以通过蒙特卡洛方法模拟出与 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 同分布的样本, 进而根据样本的信息估计 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 的分布以及分布特征。

Bootstrap 估计的思想

蒙特卡洛方法近似如下：

蒙特卡洛步骤

- 1、从总体分布 $F(x; \theta)$ 中独立产生 n 个数
据 $X_{11}, X_{12}, \dots, X_{1n}$, 得到的 θ 的估计, 记
为 $\hat{\theta}_1 = \hat{\theta}_1(X_{11}, X_{12}, \dots, X_{1n})$;
- 2、重复上述步骤 m 次, 得到的估计分别记为 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$.

基于样本 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ 推断 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 的分布,
 $E(\hat{\theta})$ 和 $\text{Var}(\hat{\theta})$ 可以分别用该样本的均值和方差估计,
即 $\hat{E}(\hat{\theta}) = m^{-1} \sum_{i=1}^m \hat{\theta}_i$, $\widehat{\text{Var}}(\hat{\theta}) = m^{-1} \sum_{i=1}^m (\hat{\theta}_i - \hat{E}(\hat{\theta}))^2$.

Bootstrap 估计的思想

如果分布 $F(x; \theta)$ 未知, 唯一的信息只有样本 $X_1, X_2, \dots, X_n$ 。不能利用上述蒙特卡洛方法从总体 $F(x; \theta)$ 中产生数据, 进而不能近似 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 的分布及其相关特征。

Bootstrap 方法就是利用样本分布 $X_1, X_2, \dots, X_n$ 代替总体分布 $F(x; \theta)$, 从分布 $X_1, X_2, \dots, X_n$ 中有放回的产生数据, 进而近似 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 的分布。

Bootstrap 估计的思想

具体步骤如下:

Bootstrap 步骤

- (1) 从样本 $X_1, X_2, \dots, X_n$ 中有放回的抽取产生数据 $X_{11}^*, X_{12}^*, \dots, X_{1n}^*$, 得到的 θ 的估计, 记为 $\hat{\theta}_1^* = \hat{\theta}_1^*(X_{11}^*, X_{12}^*, \dots, X_{1n}^*)$;
- (2) 重复上述步骤 m 次, 相应的估计分别记为 $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_m^*$ 。

利用 $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_m^*$ 近似 $\hat{\theta}$ 的分布及其特征。

Bootstrap 估计的思想

本质上, 自助法相当于用样本 $X_1, X_2, \dots, X_n$ 的经验分布 F_n 估计总体分布 F , 从经验分布中再抽样来估计总体的特征。

从经验分布再抽样本质上相当于从 $X_1, X_2, \dots, X_n$ 有放回的抽样, 以相同的概率抽取到每个样本。记 X^* 表示分布函数是 F_n 的随机变量, 则 $P(X^* = X_i) = n^{-1}, i = 1, \dots, n$ 。

用 Bootstrap 方法抽取到样本 $X_1^*, X_2^*, \dots, X_n^*$ 的经验分布 F_n^* 是 F_n 的逼近, F_n 是总体分布 F 的逼近。这两种逼近可以表示为 $F_n^* \rightarrow F_n \rightarrow F$ 。

Bootstrap 估计的思想

假设我们观察到样本 $\{2, 2, 1, 1, 5, 4, 4, 3, 1, 2\}$, 从中抽取样本点 1, 2, 3, 4, 5 的概率分别为 0.3, 0.3, 0.1, 0.2, 0.1。从中随机选择一个样本 X^* , 其分布函数就是经验分布函数, 即

$$F_{X^*}(x) = F_n(x) = \begin{cases} 0, & x < 1; \\ 0.3, & 1 \leq x < 2; \\ 0.6, & 2 \leq x < 3; \\ 0.7, & 3 \leq x < 4; \\ 0.9, & 4 \leq x < 5; \\ 1, & x \geq 5. \end{cases}$$

Bootstrap 估计的思想

需要说明的是：如果经验分布函数 $F_n(x)$ 没有靠近总体分布函数 $F(x)$ ，则重复抽样下的分布也不会靠近 $F(x)$ 。

上例中的样本实际上是从参数为 2 的泊松分布中随机产生，从样本中大量重复抽样可以很好的估计 $F_n(x)$ ，但是不能很好的估计 $F(x)$ 。因为无论重复多少次再抽样，得到的 Bootstrap 样本都不会包括总体分布的取值 0。

偏差的自助估计

基于样本数据 $X_1, X_2, \dots, X_n$, 得到感兴趣参数 θ 的估计 $\hat{\theta} =: \theta(X_1, X_2, \dots, X_n)$ 。下面分别介绍估计量偏差的 Bootstrap 估计和标准差的 Bootstrap 估计。

首先讨论 $\hat{\theta}$ 的偏差 $\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta$ 的自助估计 $\widehat{\text{Bias}}(\hat{\theta})$ 。事实上, 只需要分别估计 $E(\hat{\theta})$ 和 θ , θ 的估计 $\hat{\theta}$ 基于观察到的样本数据直接得到; 对于 $E(\hat{\theta})$ 的估计 $\hat{E}(\hat{\theta})$, 利用自助法获取到的 $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_m^*$ 的均值来估计, 也就是 $\hat{E}(\hat{\theta}) = m^{-1} \sum_{i=1}^m \hat{\theta}_i^*$ 。因此

$$\widehat{\text{Bias}}(\hat{\theta}) = m^{-1} \sum_{i=1}^m \hat{\theta}_i^* - \hat{\theta}.$$

偏差的自助估计

具体步骤

- 1、从样本 $X_1, X_2, \dots, X_n$ 中有放回的产生数据 $X_{11}^*, X_{12}^*, \dots, X_{1n}^*$, 得到 θ 的估计并记为 $\hat{\theta}_1^* = \hat{\theta}_1^*(X_{11}^*, X_{12}^*, \dots, X_{1n}^*)$;
- 2、重复上述步骤 m 次, 相应的估计分别记为 $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_m^*$, 以及基于样本 $X_1, X_2, \dots, X_n$ 得到的估计 $\hat{\theta}$;
- 3、计算 $E(\hat{\theta})$ 的自助估计 $\hat{E}(\hat{\theta}) = m^{-1} \sum_{i=1}^m \hat{\theta}_i^*$, 以及偏差自助估计 $\widehat{\text{Bias}}(\hat{\theta}) = \hat{E}(\hat{\theta}) - \hat{\theta} = m^{-1} \sum_{i=1}^m \hat{\theta}_i^* - \hat{\theta}$.

偏差的自助估计

如果偏差大于零，意味着 $\hat{\theta}$ 平均来看过高估计了 θ ；而偏差小于零，意味着 $\hat{\theta}$ 平均来看过低估计了 θ 。因此，经偏差修正的参数 θ 的估计量为 $\tilde{\theta} = \hat{\theta} - \widehat{\text{Bias}}(\hat{\theta})$ 。

设数据 $X_1, X_2, \dots, X_n$ 来自方差为 σ^2 的分布。则 σ^2 的估计为 $\hat{\sigma}^2 = n^{-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 。 $\hat{\sigma}^2$ 的偏差 $\text{Bias}(\hat{\sigma}^2) = E(\hat{\sigma}^2) - \sigma^2 = -\sigma^2/n$ 。

一个很自然的问题是： $\hat{\sigma}^2$ 偏差的自助估计

$$\widehat{\text{Bias}}(\hat{\sigma}^2) = m^{-1} \sum_{i=1}^m \hat{\sigma}_i^{2*} - \hat{\sigma}^2$$

是否为 $-\sigma^2/n$ 的无偏估计？

偏差的自助估计

首先研究 $\hat{\sigma}_1^{2*} = n^{-1} \sum_{i=1}^n (X_{1i}^* - \bar{X}_1^*)^2$ 的性质。因为 $X_{1i}^*, i = 1, 2, \dots, n$ 独立同分布, 以相同的概率在 $X_1, X_2, \dots, X_n$ 上取值, 则

$$\begin{aligned} E\{\hat{\sigma}_1^{2*} | X_1, X_2, \dots, X_n\} &= \frac{n-1}{n} \text{Var}\{X_{11}^* | X_1, X_2, \dots, X_n\} \\ &= \frac{n-1}{n} \left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 \right) = \frac{n-1}{n^2} \sum_{i=1}^n (X_i - \bar{X})^2. \end{aligned}$$

偏差的自助估计

所以

$$\begin{aligned} & E\{\widehat{\text{Bias}}(\hat{\sigma}^2) | X_1, X_2, \dots, X_n\} \\ &= E\left\{m^{-1} \sum_{i=1}^m \hat{\sigma}_i^{2*} - \hat{\sigma}^2 \mid X_1, X_2, \dots, X_n\right\} \\ &= E\{\hat{\sigma}_1^{2*} | X_1, X_2, \dots, X_n\} - \hat{\sigma}^2 \\ &= \frac{n-1}{n^2} \sum_{i=1}^n (X_i - \bar{X})^2 - \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \\ &= -\frac{1}{n^2} \sum_{i=1}^n (X_i - \bar{X})^2. \end{aligned} \tag{1}$$

偏差的自助估计

因此

$$E\{\widehat{\text{Bias}}(\hat{\sigma}^2)\} = -(n-1)\sigma^2/n^2$$

根据式 (1), 条件期望 $E\{\widehat{\text{Bias}}(\hat{\sigma}^2)|X_1, X_2, \dots, X_n\}$ 是 $\hat{\sigma}^2$ 理论偏差 $-\sigma^2/n$ 的估计, 也就是

$$E\{\widehat{\text{Bias}}(\hat{\sigma}^2)|X_1, X_2, \dots, X_n\} = -\hat{\sigma}^2/n$$

这里 σ^2 的估计 $\hat{\sigma}^2$ 为 $n^{-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 。

因为 σ^2 的估计 $\hat{\sigma}^2$ 不是无偏的, 条件期望 $E\{\widehat{\text{Bias}}(\hat{\sigma}^2)|X_1, X_2, \dots, X_n\}$ 也不是无偏估计。

偏差的自助估计

下面给出例子说明估计量偏差的 Bootstrap 估计。

例

假设 $X_1, X_2, \dots, X_n$ 是来自 $N(\mu, \sigma^2)$ 的样本, 用 *Bootstrap* 法估计 σ^2 的估计量 $\hat{\sigma}^2 = n^{-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 的偏差。

```
set.seed(1)
n=100; mu=0; sigma=2; m=2000;
X=rnorm(n,mu,sigma);
sigma2hat=mean((X-mean(X))^2) #基于样本信息, sigma^2的估计
sigma2Bst=NULL
for (i in (1:m)){
  O=sample(seq(1,n),n,replace=T)
  Bstrap_X=X[O] #有放回的从X中抽取新样本
  sigma2Bst[i]=mean((Bstrap_X-mean(Bstrap_X))^2)
  # 基于新样本, sigma^2的估计
}
Bias=mean(sigma2Bst)-sigma2hat #偏差的Bootstrap 估计
```

偏差的自助估计

例

假设 $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ 服从二元正态分布, 均值为 (μ_1, μ_2) , 方差为 (σ_1^2, σ_2^2) , 且相关系数为 ρ 。求相关系数 ρ 的估计, 并用 *Bootstrap* 方法估计其偏差。

```
set.seed(1)
library(mnormt)
n=100;
mu1=mu2=0;
sigma1=1;sigma2=2;
rho=0.6;sigma12=sigma21=rho*sigma1*sigma2;
mu=c(mu1,mu2);
Sigma=matrix(c(sigma1^2,sigma12,sigma21,sigma2^2),2,2);
Data=rmnorm(n,mu,Sigma);
X=Data[,1];Y=Data[,2];
```

偏差的自助估计

```
#基于样本信息, rho的估计
rhat=sum((X-mean(X))*(Y-mean(Y)))/
      sqrt(sum((X-mean(X))^2)*sum((Y-mean(Y))^2));
m=2000;
rhoBst=NULL;
for (i in (1:m)){
  O=sample(seq(1,n),n,replace=T);
  Bst_Data=Data[O,]; #有放回的从X中抽取新样本
  X=Bst_Data[,1];Y=Bst_Data[,2];
  rhoBst[i]=sum((X-mean(X))*(Y-mean(Y)))/
            sqrt(sum((X-mean(X))^2)*sum((Y-mean(Y))^2));
  #基于新样本, rho的估计
}
Bias=mean(rhoBst)-rhat #偏差的Bootstrap估计
```

偏差的自助估计

例

假设 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_m$ 分别是来自正态分布 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$ 的两个独立样本, 且 $\sigma_1 = 1, \sigma_2 = 2$ 。给出 $\mu_1 - \mu_2$ 的估计, 并用 *Bootstrap* 方法估计其偏差。

偏差的自助估计

```
set.seed(1)
n1=100;n2=200;mu1=0;mu2=0.3;
sigma1=1;sigma2=2;
X=rnorm(n1,mu1,sigma1); Y=rnorm(n2,mu2,sigma2)
diffhat=mean(X)-mean(Y) #基于样本信息,均值差的估计
m=2000; diffBst=NULL;
for (i in (1:m)){
  O1=sample(seq(1,n1),n1,replace=T);
  O2=sample(seq(1,n2),n2,replace=T);
  Bst_X=X[O1];Bst_Y=Y[O2]; #分别有放回的从X,Y中抽取新样本
  diffBst[i]=mean(Bst_X)-mean(Bst_Y)#基于新样本,均值差的估计
}
Bias=mean(diffBst)-diffhat #偏差的Bootstrap估计
```

估计量标准差的 Bootstrap 估计

关于估计量 $\hat{\theta}$ 的分布，在前面讲了估计量 $\hat{\theta}$ 抽样分布的 Bootstrap 估计，则 $\hat{\theta}$ 的标准差 $\widehat{SE}(\hat{\theta})$ 的 Bootstrap 估计，就是采用 $\hat{\theta}$ 分布 Bootstrap 估计的标准差。

估计量标准差的 Bootstrap 估计

标准差估计具体步骤

- 1、从分布 $X_1, X_2, \dots, X_n$ 中有放回的产生数据 $X_{11}^*, X_{12}^*, \dots, X_{1n}^*$, 得到 θ 的估计, 记为 $\hat{\theta}_1^* = \hat{\theta}_1^*(X_{11}^*, X_{12}^*, \dots, X_{1n}^*)$;
- 2、重复上述步骤 m 次, 相应的估计分别记为 $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_m^*$;
- 3、计算 $\bar{\hat{\theta}}^* = m^{-1} \sum_{i=1}^m \hat{\theta}_i^*$, $\hat{\theta}$ 标准差的自助估计为

$$\widehat{\text{SE}}(\hat{\theta}) = \left\{ \frac{1}{m} \sum_{i=1}^m (\hat{\theta}_i^* - \bar{\hat{\theta}}^*)^2 \right\}^{1/2},$$

相应的得到自助法估计的方差。

估计量标准差的 Bootstrap 估计

用自助法估计 $\hat{\theta}$ 的方差 $\text{Var}(\hat{\theta})$, 该方差无妨记为 $\widehat{\text{Var}}(\hat{\theta})$, 一个很自然的问题是: 自助法得到的估计 $\widehat{\text{Var}}(\hat{\theta})$ 和 $\text{Var}(\hat{\theta})$ 之间的关系是什么? 下面通过一个简单例子说明。

假设 $X_1, X_2, \dots, X_n$ 是来自均值为 μ , 方差为 σ^2 的分布, 感兴趣的参数为 $\theta = \mu$ 。则 $\hat{\theta} = \hat{\mu} = n^{-1} \sum_{i=1}^n X_i$, $\text{Var}(\hat{\theta}) = n^{-1} \sigma^2$ 。
 $\text{Var}(\hat{\theta})$ 的 Bootstrap 估计为

$$\widehat{\text{Var}}(\hat{\theta}) = \frac{1}{m} \sum_{i=1}^m (\hat{\theta}_i^* - \bar{\hat{\theta}}^*)^2 =: \frac{1}{m} \sum_{i=1}^m (\hat{\mu}_i^* - \bar{\hat{\mu}}^*)^2.$$

估计量标准差的 Bootstrap 估计

首先计算

$$\begin{aligned} & E\{\widehat{\text{Var}}(\hat{\theta})|(X_1, X_2, \dots, X_n)\} \\ &= E\left\{\frac{1}{m} \sum_{i=1}^m \hat{\mu}_i^{*2} - \bar{\hat{\mu}}^{*2} | (X_1, X_2, \dots, X_n)\right\} \\ &= E\{\hat{\mu}_1^{*2} | (X_1, X_2, \dots, X_n)\} - E\{\bar{\hat{\mu}}^{*2} | (X_1, X_2, \dots, X_n)\}. \end{aligned}$$

下面分别计算 $E\{\hat{\mu}_1^{*2} | (X_1, X_2, \dots, X_n)\}$ 和 $E\{\bar{\hat{\mu}}^{*2} | (X_1, X_2, \dots, X_n)\}$ 。

估计量标准差的 Bootstrap 估计

注意到

$$\begin{aligned} & E\{\hat{\mu}_1^{*2} | (X_1, X_2, \dots, X_n)\} \\ = & E\left\{ \frac{1}{n^2} (X_{11}^* + X_{12}^* + \dots + X_{1n}^*)^2 | (X_1, X_2, \dots, X_n) \right\} \\ = & \frac{1}{n} E\{X_{11}^{*2} | (X_1, X_2, \dots, X_n)\} + \frac{n-1}{n} E^2\{X_{11}^* | (X_1, X_2, \dots, X_n)\} \\ = & \frac{1}{n^2} \sum_{i=1}^n X_i^2 + \frac{n-1}{n} \left(\frac{1}{n} \sum_{i=1}^n X_i \right)^2, \end{aligned} \quad (2)$$

估计量标准差的 Bootstrap 估计

以及

$$\begin{aligned}
 & E\{\bar{\hat{\mu}}^{*2} | (X_1, X_2, \dots, X_n)\} \\
 = & E\left\{\frac{1}{m^2}(\hat{\mu}_1^* + \dots + \hat{\mu}_m^*)^2 | (X_1, X_2, \dots, X_n)\right\} \\
 = & \frac{1}{m}E\{\hat{\mu}_1^{*2} | (X_1, X_2, \dots, X_n)\} + \frac{m-1}{m}E^2\{\hat{\mu}_1^* | (X_1, X_2, \dots, X_n)\} \\
 = & \frac{1}{m} \left\{ \frac{1}{n^2} \sum_{i=1}^n X_i^2 + \frac{n-1}{n} \left(\frac{1}{n} \sum_{i=1}^n X_i \right)^2 \right\} \\
 & + \frac{m-1}{m} \left(\frac{X_1 + \dots + X_n}{n} \right)^2,
 \end{aligned} \tag{3}$$

估计量标准差的 Bootstrap 估计

结合式 (2), (3), 可得

$$\begin{aligned} & E\{\widehat{\text{Var}}(\hat{\theta})|(X_1, X_2, \dots, X_n)\} \\ &= \frac{m-1}{m} \left\{ \frac{1}{n^2} \sum_{i=1}^n X_i^2 + \frac{n-1}{n} \left(\frac{1}{n} \sum_{i=1}^n X_i \right)^2 \right\} - \frac{m-1}{m} \left(\frac{X_1 + \dots + X_n}{n} \right)^2 \\ &= \frac{m-1}{m} \left\{ \frac{1}{n^2} \sum_{i=1}^n X_i^2 - \frac{1}{n} \bar{X}^2 \right\} = \frac{m-1}{mn^2} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{m-1}{mn} \hat{\sigma}^2, \end{aligned}$$

这里 $\hat{\sigma}^2 = n^{-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 。因此自助法得到的估计 $\widehat{\text{Var}}(\hat{\theta})$ 的条件期望为 $(mn)^{-1}(m-1)\hat{\sigma}^2$, 是方差 $\text{Var}(\hat{\theta}) = n^{-1}\sigma^2$ 的估计。

估计量标准差的 Bootstrap 估计

例

假设 $X_1, X_2, \dots, X_n$ 是来自 $N(\mu, \sigma^2)$ 的样本, 用 $\hat{\mu} = n^{-1} \sum_{i=1}^n X_i$ 估计 μ , 并求该估计量方差的 *Bootstrap* 估计。

```
set.seed(1)
n=100; mu=0; sigma=2; m=2000
X=rnorm(n,mu,sigma);
muhat=mean(X) #基于样本信息, mu的估计
muBst=NULL
for (i in (1:m)){
  O=sample(seq(1,n),n,replace=T)
  Bstrap_X=X[O] #有放回的从X中抽取新样本
  muBst[i]=mean(Bstrap_X) #基于新样本, mu的估计
}
var_muBst=mean((muBst-mean(muBst))^2) #方差的Bootstrap估计
```

估计量标准差的 Bootstrap 估计

例

假设 $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ 服从二元正态分布, 均值为 (μ_1, μ_2) , 方差为 (σ_1^2, σ_2^2) , 且相关系数为 ρ 。求相关系数 ρ 的估计, 并用 *Bootstrap* 方法估计其方差。

```
set.seed(1)
library(mnormt)
n=100;
mu1=mu2=0;
sigma1=1;sigma2=2;
rho=0.6;sigma12=sigma21=rho*sigma1*sigma2;
mu=c(mu1,mu2);
Sigma=matrix(c(sigma1^2,sigma12,sigma21,sigma2^2),2,2);
Data=rmnorm(n,mu,Sigma);
X=Data[,1];Y=Data[,2];
```


估计量标准差的 Bootstrap 估计

```
rhohat=sum((X-mean(X))*(Y-mean(Y)))/ #基于样本信息, rho的估计
      sqrt(sum((X-mean(X))^2)*sum((Y-mean(Y))^2));
m=2000;
rhoBst=NULL;
for (i in (1:m)){
  O=sample(seq(1,n),n,replace=T);
  Bst_Data=Data[O,]; #有放回的抽取新样本
  X=Bst_Data[,1];Y=Bst_Data[,2];
  rhoBst[i]=sum((X-mean(X))*(Y-mean(Y)))/
            sqrt(sum((X-mean(X))^2)*sum((Y-mean(Y))^2));
  #基于新样本, rho的估计
}
var_rhoBst=mean((rhoBst-mean(rhoBst))^2) # 方差的Bootstrap估计
```

估计量标准差的 Bootstrap 估计

例

假设 $X_1, X_2, \dots, X_{n_1}$ 和 $Y_1, Y_2, \dots, Y_{n_2}$ 是来自正态分布 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$ 的两个独立样本。给出 σ_1^2/σ_2^2 的估计, 并用 *Bootstrap* 方法估计其方差。

```
set.seed(1)
n1=100;n2=200;
mu1=0;mu2=0.2;
sigma1=1;sigma2=2;
X=rnorm(n1,mu1,sigma1)
Y=rnorm(n2,mu2,sigma2)
Sx=sum((X-mean(X))^2)/(n1-1);Sy=sum((Y-mean(Y))^2)/(n2-1)
ratiohat=Sx/Sy #基于样本信息, 方差比值的估计
```

估计量标准差的 Bootstrap 估计

```
m=2000;
ratioBst=NULL;
for (i in (1:m)){
  O1=sample(seq(1,n1),n1,replace=T);
  O2=sample(seq(1,n2),n2,replace=T);
  X_Bst=X[O1];Y_Bst=Y[O2]; #分别有放回的从X,Y抽取新样本
  Sx_Bst=sum((X_Bst-mean(X_Bst))^2)/(n1-1);
  Sy_Bst=sum((Y_Bst-mean(Y_Bst))^2)/(n2-1);
  ratioBst[i]=Sx_Bst/Sy_Bst #基于新样本,方差比值的估计
}
var_ratioBst=mean((ratioBst-mean(ratioBst))^2)
#估计量方差的Bootstrap估计
```

基于 Jackknife 法的估计

在 Bootstrap 方法提出之前, 另外一种有影响力的重抽样方法是由 Quenouille(1949, 1956) 提出的 Jackknife 法。

Jackknife 估计的基本思想是, 对于从样本 $X_1, X_2, \dots, X_n$ 中获得的感兴趣参数 θ 的估计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$, 其分布特征(如估计量的偏差和方差)可以用 Jackknife 法得到。

对于给定样本 $X_1, X_2, \dots, X_n$, 每次删除其中一个(或者几个)样本点, 基于剩下的样本采用相同的估计量公式得到 θ 的估计, 经过逐个删除并分别计算估计之后, 便可以得到一系列估计值, 基于这些估计值进而估计 $\hat{\theta}$ 的分布特征。

基于 Jackknife 法的估计

去掉一个数据的 Jackknife 计算 θ 的具体步骤如下:

Jackknife 计算步骤

- 1、从观测样本 $X_1, X_2, \dots, X_n$ 中去掉第 i 个数据 X_i 后的剩余样本, 定义为第 i 个 Jackknife 样本, 记为 $X_{(-i)} = (X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_n)$;
- 2、基于第 i 个 Jackknife 样本 $X_{(-i)}, i = 1, 2, \dots, n$, 得到相应的估计 $\hat{\theta}_{(-i)} = \hat{\theta}(X_{(-i)}), i = 1, \dots, n$ 。

Jackknife 法就是利用 $\hat{\theta}_{(-i)} = \hat{\theta}(X_{(-i)}), i = 1, \dots, n$ 得到估计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 的分布特征。

估计量偏差的 Jackknife 估计

基于 $\hat{\theta}_{(-i)}$, $\hat{\theta}$ 的偏差 $\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta$ 的 Jackknife 估计为

$$\widehat{\text{Bias}}(\hat{\theta}) = (n-1) \left(\frac{1}{n} \sum_{i=1}^n \hat{\theta}_{(-i)} - \hat{\theta} \right) = \frac{n-1}{n} \sum_{i=1}^n (\hat{\theta}_{(-i)} - \hat{\theta}). \quad (4)$$

以总体方差 $\theta = \sigma^2$ 为例, 对于方差的估计
 $\hat{\theta} = n^{-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 。估计量 $\hat{\theta}$ 是 σ^2 的有偏估计, 偏差
为 $\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta = -n^{-1}\sigma^2$ 。

估计量偏差的 Jackknife 估计

对于每一个 Jackknife 估计 $\hat{\theta}_{(-i)}$, 基于样本量 $n-1$ 的样本 $X_{(-i)} = (X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_n)$ 构造, 因此

$$\begin{aligned} E(\hat{\theta}_{(-i)} - \hat{\theta}) &= E(\hat{\theta}_{(-i)} - \theta) - E(\hat{\theta} - \theta) = \text{Bias}(\hat{\theta}_{(-i)}) - \text{Bias}(\hat{\theta}) \\ &= -\frac{\sigma^2}{n-1} - \left(-\frac{\sigma^2}{n}\right) = -\frac{\sigma^2}{n(n-1)} = \frac{\text{Bias}(\hat{\theta})}{n-1}. \end{aligned}$$

估计量偏差的 Jackknife 估计

根据上式可得

$$\text{Bias}(\hat{\theta}) = (n-1)\text{E}(\hat{\theta}_{(-i)} - \hat{\theta}). \quad (5)$$

根据式 (4), (5), 可得

$$\begin{aligned} \text{E}\{\widehat{\text{Bias}}(\hat{\theta})\} &= \frac{n-1}{n}\text{E}\left\{\sum_{i=1}^n(\hat{\theta}_{(-i)} - \hat{\theta})\right\} \\ &= (n-1)\text{E}(\hat{\theta}_{(-1)} - \hat{\theta}) = \text{Bias}(\hat{\theta}). \end{aligned}$$

因此偏差 Jackknife 估计 $\widehat{\text{Bias}}(\hat{\theta})$ 是偏差 $\text{Bias}(\hat{\theta})$ 的无偏估计。

估计量偏差的 Jackknife 估计

下面给出例子说明估计量偏差的 Jackknife 估计。

例

假设 $X_1, \dots, X_n$ 是来自 $N(\mu, \sigma^2)$ 的样本, 用 $\hat{\sigma}^2 = n^{-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 估计 σ^2 , 并用 Jackknife 法估计其偏差。

估计量偏差的 Jackknife 估计

```
set.seed(1)
n=100;
mu=0; sigma=2;
X=rnorm(n,mu,sigma);
sigma2hat=sum((X-mean(X))^2)/n #基于原样本,  $\sigma^2$ 的估计
sigma2Jack=NULL
for (i in (1:n)){
  Jack_X=X[-i] #去掉第b个样本点
  sigma2Jack[i]=sum((Jack_X-mean(Jack_X))^2)/(n-1)
  # 基于新样本,  $\sigma^2$ 的估计
}
Bias=(n-1)*mean(sigma2Jack-sigma2hat) #偏差的Jackknife估计
```

估计量偏差的 Jackknife 估计

例

假设 $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ 服从二元正态分布, 均值为 (μ_1, μ_2) , 方差为 (σ_1^2, σ_2^2) , 且相关系数为 ρ 。求相关系数 ρ 的估计, 并用 *Jackknife* 法估计其偏差。

```
set.seed(1)
library(mnormt)
n=100;
mu1=mu2=0;
sigma1=1;sigma2=2;
rho=0.6;sigma12=sigma21=rho*sigma1*sigma2;
mu=c(mu1,mu2);
Sigma=matrix(c(sigma1^2,sigma12,sigma21,sigma2^2),2,2);
Data=rmnorm(n,mu,Sigma);
X=Data[,1];Y=Data[,2];
```

估计量偏差的 Jackknife 估计

```
rhohat=sum((X-mean(X))*(Y-mean(Y)))/ #基于原样本, rho的估计
  sqrt(sum((X-mean(X))^2)*sum((Y-mean(Y))^2));
rhoJack=NULL;
for (i in (1:n)){
  Jack_Data=Data[-i,]; #去掉第b组 (X,Y)
  X=Jack_Data[,1];Y=Jack_Data[,2];
  rhoJack[i]=sum((X-mean(X))*(Y-mean(Y)))/
    sqrt(sum((X-mean(X))^2)*sum((Y-mean(Y))^2));
  #基于新样本, rho的估计
}
Bias=(n-1)*mean(rhoJack-rhohat) #偏差的Jackknife估计
```

估计量标准差的 Jackknife 估计

对于估计量 $\hat{\theta}$, 其标准差的 Jackknife 估计定义为

$$\widehat{\text{SE}}_{\text{Jack}}(\hat{\theta}) = \left\{ \frac{n-1}{n} \sum_{i=1}^n (\hat{\theta}_{(-i)} - \bar{\hat{\theta}}_{(\cdot)})^2 \right\}^{1/2}, \quad (6)$$

这里 $\bar{\hat{\theta}}_{(\cdot)} = n^{-1} \sum_{i=1}^n \hat{\theta}_{(-i)}$ 。相应地, 根据式 (6) 可得到方差的 Jackknife 估计。

估计量标准差的 Jackknife 估计

以 θ 是总体均值为例, $\hat{\theta} = \bar{X} = n^{-1} \sum_{i=1}^n X_i$, 其方差为 $\text{Var}(\hat{\theta}) = n^{-1} \sigma^2$ 。由于

$$\hat{\theta}_{(-i)} = \frac{n\bar{X} - X_i}{n-1},$$

可得

$$\bar{\hat{\theta}}_{(\cdot)} = n^{-1} \sum_{i=1}^n \hat{\theta}_{(-i)} = n^{-1} \sum_{i=1}^n \frac{n\bar{X} - X_i}{n-1} = \frac{(n^2 - n)\bar{X}}{n(n-1)} = \bar{X}.$$

估计量标准差的 Jackknife 估计

基于上述结果, 不难得到

$$\begin{aligned}\widehat{\text{Var}}_{\text{Jack}}(\hat{\theta}) &= \frac{n-1}{n} \sum_{i=1}^n (\hat{\theta}_{(-i)} - \bar{\hat{\theta}}_{(\cdot)})^2 \\ &= \frac{n-1}{n} \sum_{i=1}^n \left(\frac{n\bar{X} - X_i}{n-1} - \bar{X} \right)^2 = \frac{1}{n(n-1)} \sum_{i=1}^n (X_i - \bar{X})^2.\end{aligned}$$

因此 $E(\widehat{\text{Var}}_{\text{Jack}}(\hat{\theta})) = n^{-1}\sigma^2$, 也就是估计量 θ 的方差的 Jackknife 估计是无偏估计。

下面给出例子说明估计量方差的 Jackknife 估计。

例

假设 $X_1, X_2, \dots, X_n$ 是来自 $N(\mu, \sigma^2)$ 的样本, 用 $\hat{\sigma}^2 = n^{-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 估计 σ^2 , 并用 Jackknife 法估计其方差。

估计量标准差的 Jackknife 估计

```
set.seed(1)
n=100;
mu=0;
sigma=2;
X=rnorm(n,mu,sigma);
muhat=mean(X) #基于样本信息, mu的估计
muJack=NULL
for (i in (1:n)){
  Jack_X=X[-i]
  muJack[i]=mean(Jack_X) #基于新样本, mu的估计
}
Varhat=(n-1)*mean((muJack-mean(muJack))^2) #方差Jackknife估计
```


估计量标准差的 Jackknife 估计

例

假设 $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ 服从二元正态分布, 均值为 (μ_1, μ_2) , 方差为 (σ_1^2, σ_2^2) , 且相关系数为 ρ 。求相关系数 ρ 的估计, 并用 *Jackknife* 方法估计其方差。

```
set.seed(1)
library(mnormt)
n=100;
mu1=mu2=0;
sigma1=1;sigma2=2;
rho=0.6;sigma12=sigma21=rho*sigma1*sigma2;
mu=c(mu1,mu2);
Sigma=matrix(c(sigma1^2,sigma12,sigma21,sigma2^2),2,2);
```

估计量标准差的 Jackknife 估计

```
Data=rmnorm(n,mu,Sigma);
X=Data[,1];Y=Data[,2];
rho_hat=sum((X-mean(X))*(Y-mean(Y)))/ #基于样本信息, rho的估计
      sqrt(sum((X-mean(X))^2)*sum((Y-mean(Y))^2));
rhoJack=NULL;
for (i in (1:n)){
  Jack_Data=Data[-i,];
  X=Jack_Data[,1];Y=Jack_Data[,2];
  rhoJack[i]=sum((X-mean(X))*(Y-mean(Y)))/
            sqrt(sum((X-mean(X))^2)*sum((Y-mean(Y))^2));
  #基于新样本, rho的估计
}
Var_hat=(n-1)*mean((rhoJack-mean(rhoJack))^2)
```

Jackknife-after-Bootstrap 估计

前面介绍了估计量偏差和标准差的 Bootstrap 估计，这些估计本身又是估计量，那么这些估计量的方差该如何估计呢？一种方法就是使用 Jackknife 方法来估计这些估计量的方差。

下面步骤给出 $\hat{\theta}$ 标准差的 Jackknife-after-Bootstrap 估计。

Jackknife-after-Bootstrap 估计步骤

- 1、固定 i ，从观测数据 $X_{(-i)} = (X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_n)$ 中有放回的产生数据 $X_{(-i),1}^* = (X_{11}^*, X_{12}^*, \dots, X_{1,n-1}^*)$ ，基于此样本得到 θ 的估计为 $\hat{\theta}_{(-i),1}^* = \hat{\theta}_{(-i),1}^*(X_{(-i),1}^*)$ ；
- 2、重复上述步骤 m 次，相应的估计分别记为 $\hat{\theta}_{(-i),1}^*, \hat{\theta}_{(-i),2}^*, \dots, \hat{\theta}_{(-i),m}^*$ ；

Jackknife-after-Bootstrap 估计

3、计算 $\bar{\theta}_{(-i)}^* = m^{-1} \sum_{k=1}^m \hat{\theta}_{(-i),k}^*$, 基于 $\hat{\theta}_{(-i),1}^*, \hat{\theta}_{(-i),2}^*, \dots, \hat{\theta}_{(-i),m}^*$ $\hat{\theta}$ 标准差的 Bootstrap 估计为

$$\widehat{SE}_{(-i)}(\hat{\theta}) = \left\{ \frac{1}{m} \sum_{k=1}^m (\hat{\theta}_{(-i),k}^* - \bar{\theta}_{(-i)}^*)^2 \right\}^{1/2};$$

4、对于不同的 $i = 1, 2, \dots, n$, 重复上述步骤 (1)-(3), 得到 $\widehat{SE}_{(-1)}(\hat{\theta}), \widehat{SE}_{(-2)}(\hat{\theta}), \dots, \widehat{SE}_{(-n)}(\hat{\theta})$, 则 $\widehat{SE}(\hat{\theta})$ 的标准差的 Jackknife 估计为

$$\widehat{SE}_{Jack}(\widehat{SE}(\hat{\theta})) = \left\{ \frac{n-1}{n} \sum_{i=1}^n \left(\widehat{SE}_{(-i)}(\hat{\theta}) - \overline{\widehat{SE}_{(-i)}(\hat{\theta})} \right)^2 \right\}^{1/2},$$

这里 $\overline{\widehat{SE}_{(-i)}(\hat{\theta})} = n^{-1} \sum_{i=1}^n \widehat{SE}_{(-i)}(\hat{\theta})$

Jackknife-after-Bootstrap 估计

例

假设 $X_1, X_2, \dots, X_n$ 是来自 $N(\mu, \sigma^2)$ 的样本, 用 *Bootstrap* 方法估计 μ 的估计量 $\hat{\mu} = n^{-1} \sum_{i=1}^n X_i$ 的方差, 并用 *Jackknife* 方法估计 *Bootstrap* 方差估计量的方差。

```
set.seed(1)
n=100;
mu=0;
sigma=2;
X=rnorm(n,mu,sigma);
m=2000
muBst=var_muBst=NULL
```

Jackknife-after-Bootstrap 估计

```
for (i in (1:n)){  
  X_Jack=X[-i];  
  for (j in (1:m)){  
    O=sample(seq(1,n-1),n-1,replace=T)  
    X_Jack_Bstrap=X_Jack[O]  
    #去掉第i个样本后，有放回抽样得到的新样本  
    muBst[j]=mean(X_Jack_Bstrap) #基于新样本，得到的mu的估计  
  }  
  var_muBst[i]=mean((muBst-mean(muBst))^2)  
  #Bootstrap 方法得到的方差估计  
}  
varJack_muBst=(n-1)*mean((var_muBst-mean(var_muBst))^2)  
#Jackknife方法得到的Bootstrap估计量的方法
```

Jackknife-after-Bootstrap 估计

例

假设 $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ 服从二元正态分布, 均值为 (μ_1, μ_2) , 方差为 (σ_1^2, σ_2^2) , 且相关系数为 ρ 。用 *Bootstrap* 方法估计 ρ 的估计量的方差, 并用 *Jackknife* 方法估计 *Bootstrap* 方差估计量的方差。

Jackknife-after-Bootstrap 估计

```
set.seed(1)
library(mnormt)
n=100;
mu1=mu2=0;
sigma1=1;sigma2=2;
rho=0.6;sigma12=sigma21=rho*sigma1*sigma2;
mu=c(mu1,mu2);
Sigma=matrix(c(sigma1^2,sigma12,sigma21,sigma2^2),2,2);
Data=rmnorm(n,mu,Sigma);
X=Data[,1];Y=Data[,2];
rhoht=sum((X-mean(X))*(Y-mean(Y)))/ #基于样本信息, rho的估计
  sqrt(sum((X-mean(X))^2)*sum((Y-mean(Y))^2));
m=2000;
rhoBst=var_rhoBst=NULL;
```


Jackknife-after-Bootstrap 估计

```
for (i in (1:n)){  
  Data_Jack=Data[-i,];  
  for (j in (1:m)){  
    O=sample(seq(1,n-1),n-1,replace=T);  
    Data_Jack_Bst=Data_Jack[O,];  
    X=Data_Jack_Bst[,1];Y=Data_Jack_Bst[,2];  
    rhoBst[j]=sum((X-mean(X))*(Y-mean(Y)))/  
      sqrt(sum((X-mean(X))^2)*sum((Y-mean(Y))^2));  
    #rho的Bootstrap估计  
  }  
  var_rhoBst[i]=mean((rhoBst-mean(rhoBst))^2)  
  #Bootstrap 方法得到的方差估计  
}  
varJack_rhoBst=(n-1)*mean((var_rhoBst-mean(var_rhoBst))^2)  
#Jackknife方法得到的Bootstrap估计量的方法
```

基于 Bootstrap 法的置信区间估计

本节介绍几种利用 Bootstrap 法构造感兴趣参数 θ 的渐近置信区间的方法。

主要包括标准正态 Bootstrap 置信区间, 基本的 Bootstrap 置信区间, Bootstrap 百分位数 (percentile) 置信区间以及 Bootstrap 的 t 置信区间。

基于 Bootstrap 法的置信区间估计

标准正态 Bootstrap 置信区间是一种比较简单的方法。假设 $\hat{\theta}$ 是参数 θ 的无偏估计量，估计量的标准差为 $SE(\hat{\theta})$ 。如果

$$Z = \frac{\hat{\theta} - E\hat{\theta}}{SE(\hat{\theta})} = \frac{\hat{\theta} - \theta}{SE(\hat{\theta})}$$

渐近服从标准正态分布。

θ 渐近的 $100(1 - \alpha)\%$ 标准正态 Bootstrap 置信区间为

$$\hat{\theta} \pm z_{\alpha/2} \widehat{SE}_B(\hat{\theta}),$$

这里 $z_{\alpha/2} = \Phi^{-1}(1 - \alpha/2)$, $\widehat{SE}_B(\hat{\theta})$ 为 $\hat{\theta}$ 标准差的 Bootstrap 估计。标准正态 Bootstrap 置信区间需要渐近正态性条件，以及 $\hat{\theta}$ 为 θ 的无偏估计。

基于 Bootstrap 法的置信区间估计

基本的 Bootstrap 置信区间的想法是通过计算估计 $\hat{\theta}$ 的 $\alpha/2$ 和 $1 - \alpha/2$ 的 Bootstrap 百分位数构造, 具体表达式为

$$[\hat{\theta}_{([m\alpha/2])}^*, \hat{\theta}_{([m(1-\alpha/2)])}^*],$$

这里 $\hat{\theta}_{([m\alpha/2])}^*$ 和 $\hat{\theta}_{([m(1-\alpha/2)])}^*$ 是自助法得到估计 $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_m^*$ 的第 $[m\alpha/2]$ 和 $[m(1 - \alpha/2)]$ 个次序统计量的值。

本质上, $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_m^*$ 可以看作是从 $\hat{\theta}$ 分布中抽取的 Bootstrap 样本, 因此 $P(\hat{\theta}_{([m\alpha/2])}^* < \hat{\theta} < \hat{\theta}_{([m(1-\alpha/2)])}^*) \approx 1 - \alpha$ 。由于 $\hat{\theta}$ 为 θ 的估计, 所以 $P(\hat{\theta}_{([m\alpha/2])}^* < \theta < \hat{\theta}_{([m(1-\alpha/2)])}^*) \approx 1 - \alpha$ 。

基于 Bootstrap 法的置信区间估计

Bootstrap 百分位数 (percentile) 置信区间基于等式 $P(L < \hat{\theta} - \theta < U) = 1 - \alpha$ 构造。本质上, 通过分布 $\hat{\theta} - \theta$ 的 $\alpha/2$ 和 $1 - \alpha/2$ 的分位点 L 和 U 得到 θ 的置信区间。

两个分位数可通过 $\hat{\theta}_{[m\alpha/2]}^* - \hat{\theta}$ 和 $\hat{\theta}_{[m(1-\alpha/2)]}^* - \hat{\theta}$ 近似, 也就是

$$P\left(\hat{\theta}_{[m\alpha/2]}^* - \hat{\theta} < \hat{\theta} - \theta < \hat{\theta}_{[m(1-\alpha/2)]}^* - \hat{\theta}\right) \approx 1 - \alpha.$$

等价的, 可得

$$P\left(2\hat{\theta} - \hat{\theta}_{[m(1-\alpha/2)]}^* < \theta < 2\hat{\theta} - \hat{\theta}_{[m\alpha/2]}^*\right) \approx 1 - \alpha.$$

因此, $100(1 - \alpha)\%$ 置信区间为 $[2\hat{\theta} - \hat{\theta}_{[m(1-\alpha/2)]}^*, 2\hat{\theta} - \hat{\theta}_{[m\alpha/2]}^*]$ 。

基于 Bootstrap 法的置信区间估计

接下来介绍 Bootstrap 的 t 置信区间方法, 即使 $\hat{\theta}$ 的分布是正态分布, 且 $\hat{\theta}$ 为 θ 的无偏估计, $(\hat{\theta} - \theta)/\widehat{SE}_B(\hat{\theta})$ 的分布也不一定是正态的, 这里 $\widehat{SE}_B(\hat{\theta})$ 是 $\hat{\theta}$ 的 Bootstrap 的标准差估计。

Bootstrap 的 t 置信区间方法本质上用 Bootstrap 法近似

$$t = \frac{\hat{\theta} - \theta}{\widehat{SE}_B(\hat{\theta})}$$

的分布。

基于 Bootstrap 法的置信区间估计

具体步骤

- 1、从样本 $(X_1, X_2, \dots, X_n)$ 中有放回的产生 $(X_{11}^*, X_{12}^*, \dots, X_{1n}^*)$, 得到的 θ 的估计, 记为 $\hat{\theta}_1^* =: \hat{\theta}_1^*(X_{11}^*, X_{12}^*, \dots, X_{1n}^*)$;
- 2、从抽样样本 $(X_{11}^*, X_{12}^*, \dots, X_{1n}^*)$ 中再抽样 k 次, 得到 $\hat{\theta}_1^*$ 的标准差 $\widehat{SE}(\hat{\theta}_1^*)$, 计算

$$t_1^* = \frac{\hat{\theta}_1^* - \hat{\theta}}{\widehat{SE}(\hat{\theta}_1^*)};$$

- 3、重复上述步骤 (1)、(2) m 次, 相应的得到 $t_1^*, t_2^*, \dots, t_m^*$ 。

基于 Bootstrap 法的置信区间估计

用 $t_{([m\alpha/2])}^*$ 和 $t_{([m(1-\alpha/2)])}^*$ 分别表示 $t_1^*, t_2^*, \dots, t_m^*$ 的第 $[m\alpha/2]$ 和 $[m(1-\alpha/2)]$ 的次序统计量, 则

$$P\left(t_{([m\alpha/2])}^* < \frac{\hat{\theta} - \theta}{\widehat{SE}_B(\hat{\theta})} < t_{([m(1-\alpha/2)])}^*\right) \approx 1 - \alpha.$$

基于上式, Bootstrap 的 t 置信区间为

$$[\hat{\theta} - t_{([m(1-\alpha/2)])}^* \widehat{SE}_B(\hat{\theta}), \hat{\theta} - t_{([m\alpha/2])}^* \widehat{SE}_B(\hat{\theta})].$$

基于 Bootstrap 法的置信区间估计

例

假设 $X_1, X_2, \dots, X_n$ 是来自 $N(\mu, \sigma^2)$ 的样本, 用 *Bootstrap* 方法估计参数 μ 的置信区间。

基于 Bootstrap 法的置信区间估计

```
set.seed(1)
alpha=0.05;n=100;mu=0;sigma=1;
X=rnorm(n,mu,sigma);
muhat=mean(X) #基于样本信息, mu的估计
m=K=rep_muBst=500;muBst=t=NULL
for (i in (1:m)){
  O=sample(seq(1,n),n,replace=T)
  Bstrap_X=X[O] #有放回的从X中抽取样本
  muBst[i]=mean(Bstrap_X) #基于重抽样样本, mu的估计
  for (k in (1:K)){
    O=sample(seq(1,n),n,replace=T)
    rep_Bstrap_X=Bstrap_X[O]; #有放回的从重抽样样本中抽取样本
    rep_muBst[k]=mean(rep_Bstrap_X);
  }
  se_rep=sqrt(mean((rep_muBst-mean(rep_muBst))^2));
  #基于重抽样样本估计的估计量标准差
```

基于 Bootstrap 法的置信区间估计

```
t[i]=(muBst[i]-muhat)/se_rep;  
#基于第i组重抽样样本和估计的标准差，构建t统计量  
}  
se_muBst=sqrt(mean((muBst-mean(muBst))^2))  
#构造第一种置信区间和第四种置信区间需要的标准差估计  
L1=muhat-qnorm(1-alpha/2,0,1)*se_muBst;  
U1=muhat+qnorm(1-alpha/2,0,1)*se_muBst; #第一种区间  
smuBst=sort(muBst)  
L2=smuBst[round(m*alpha/2)];  
U2=smuBst[round(m*(1-alpha/2))]; #第二种区间  
L3=2*muhat-smuBst[round(m*(1-alpha/2))];  
U3=2*muhat-smuBst[round(m*alpha/2)]; #第三种区间  
st=sort(t)  
L4=muhat-st[round(m*(1-alpha/2))]*se_muBst;  
U4=muhat-st[round(m*alpha/2)]*se_muBst; #第四种区间  
c(L1,U1);c(L2,U2);c(L3,U3);c(L4,U4)
```

谢 谢